Pon un título a tu documento

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Pon aquí tu nombre y apellidos

2026-10-26

Índice

1. Ejercicio 1 **1**

2. Ejercicio 2 **5**

3. Ejercicio 3 **9**

4. Ejercicio 4 **15**

5. Ejercicio 5 **19**

6. Ejercicio 6 **22**

7. Ejercicio 7 **23**

8. Ejercicio 8 **27**

```
library(pacman)
packages =  c("tidyverse", "knitr", "ggplot2", "datasets", "RColorBrewer",'latex2exp')
pacman::p_load(char=packages)
```

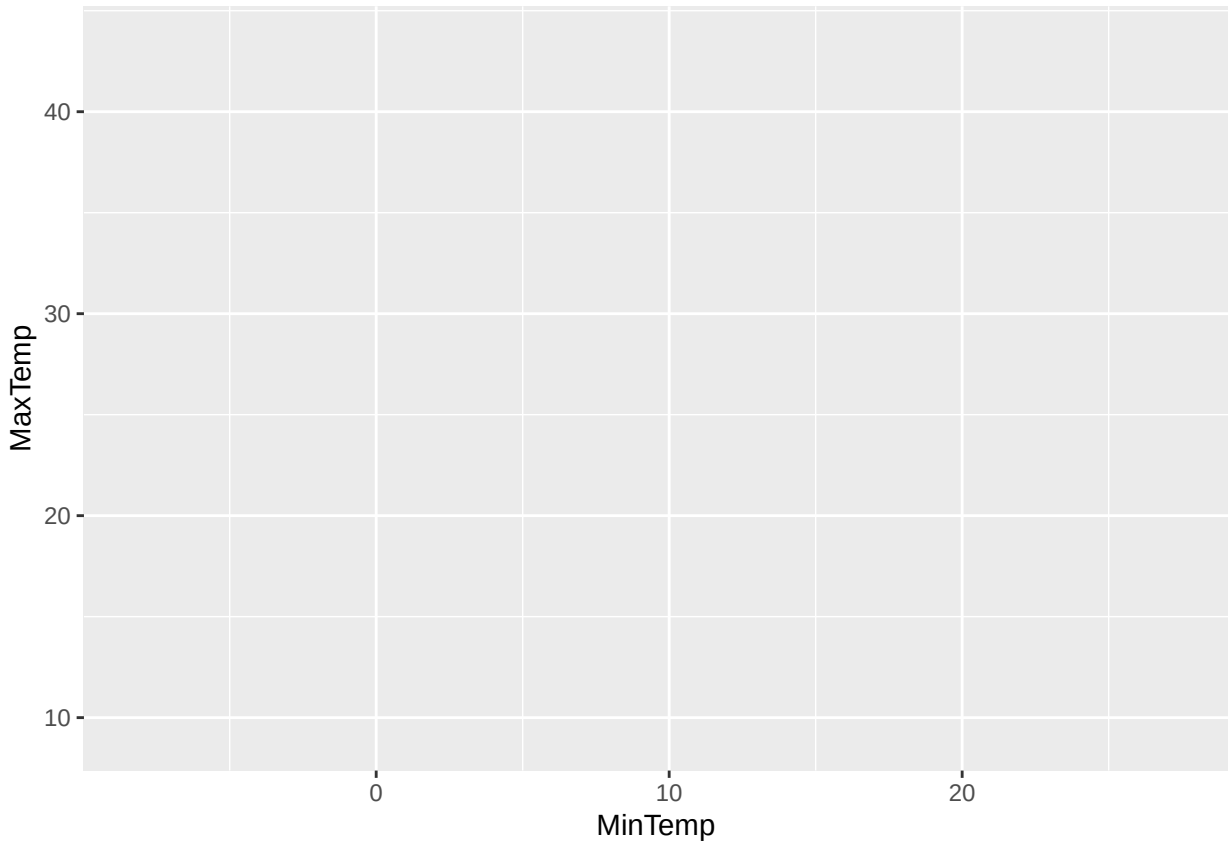
1. Ejercicio 1

1. Carga el fichero `weatherAUS.RData` utilizando lo aprendido en la práctica 1.

```
load('./data/weatherAUS.RData')
```

2. Crea un objeto ggplot denominado grafico1 en el que esté definido el conjunto de datos ds alojado en el fichero weatherAUS.RData y un aesthetics en el que en el eje x esté definida la variable MinTemp y en el eje y esté definida la variable MaxTemp.

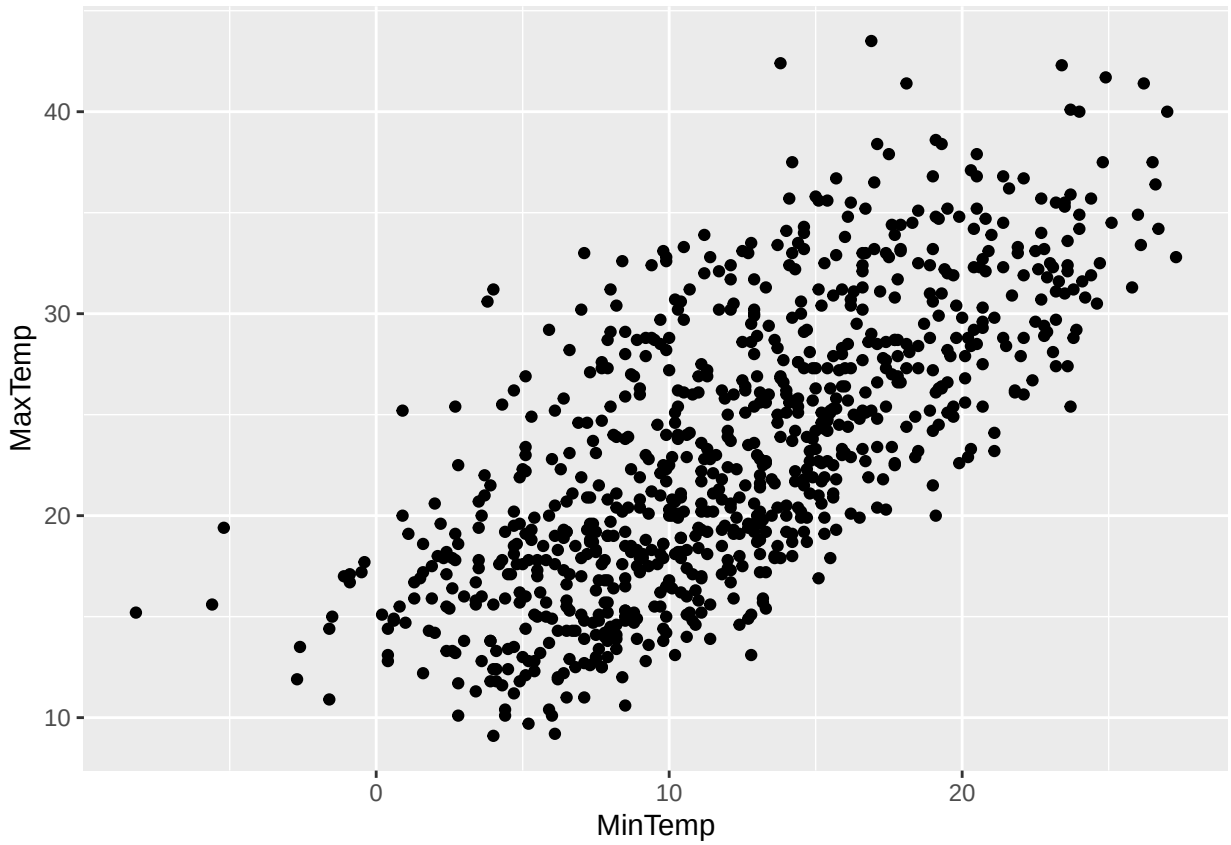
```
grafico1 <- ggplot(ds, aes(x=MinTemp, y=MaxTemp))
grafico1
```



Todavía no hay nada dibujado porque no hemos elegido ningún objeto geométrico.

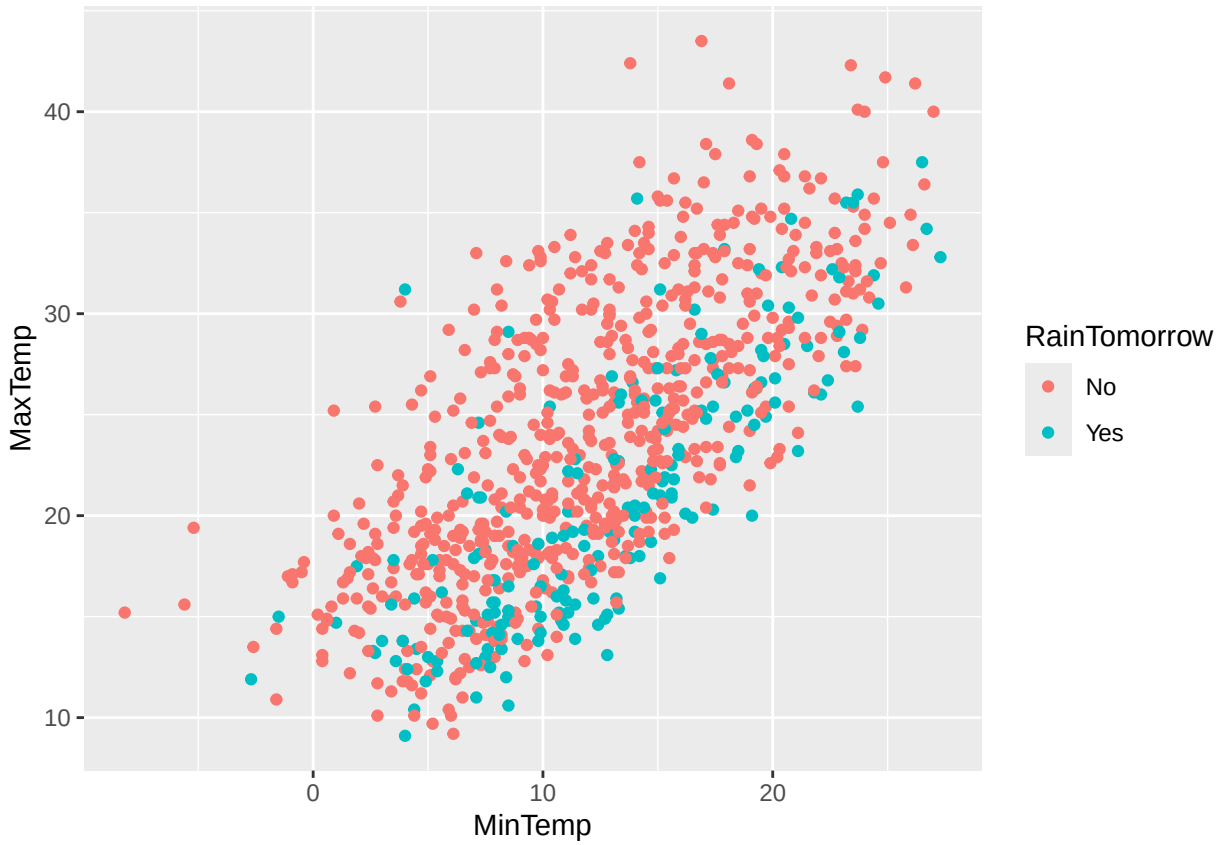
3. Añade una capa que defina el objeto geométrico necesario para construir un gráfico de dispersión de las variables MinTemp y MaxTemp.

```
grafico1 + geom_point()
```



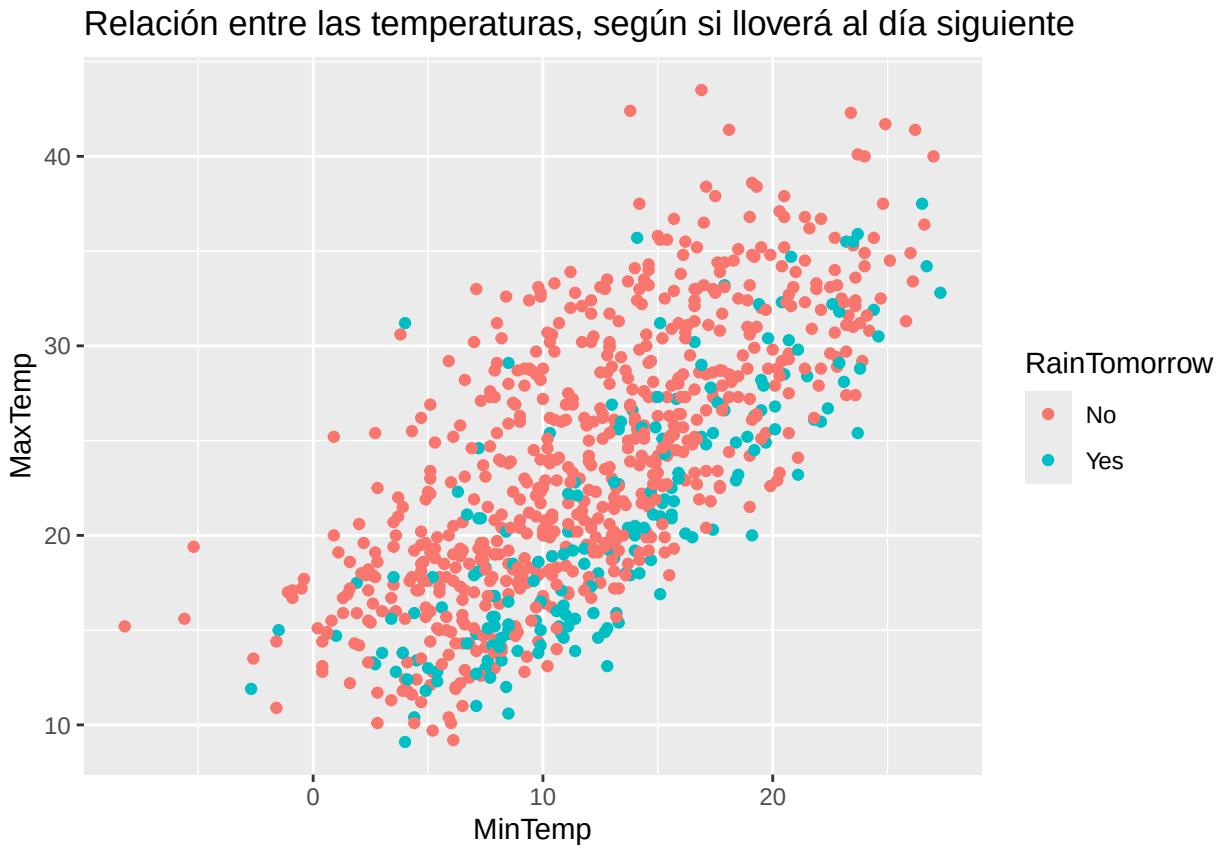
4. Genera ahora el mismo gráfico y almacénalo en grafico2 pero define el aesthetics para visualizar las variables MinTemp y MaxTemp en los ejes de la gráfica y la variable categórica RainTomorrow como el color. A partir del objeto grafico2, representa un gráfico de dispersión en el que se muestren los puntos con el color del punto correspondiente a la variable RainTomorrow.

```
grafico2 <- ggplot(ds, aes(x=MinTemp, y=MaxTemp, colour=RainTomorrow))
grafico2 + geom_point()
```



5. Añade a grafico2 una capa para incluir un título con ggtitle() y almacénalo en grafico3.

```
grafico3 <- grafico2 + ggtitle('Relación entre las temperaturas, según si lloverá al día siguiente')
grafico3 + geom_point()
```



6. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio1.pdf.

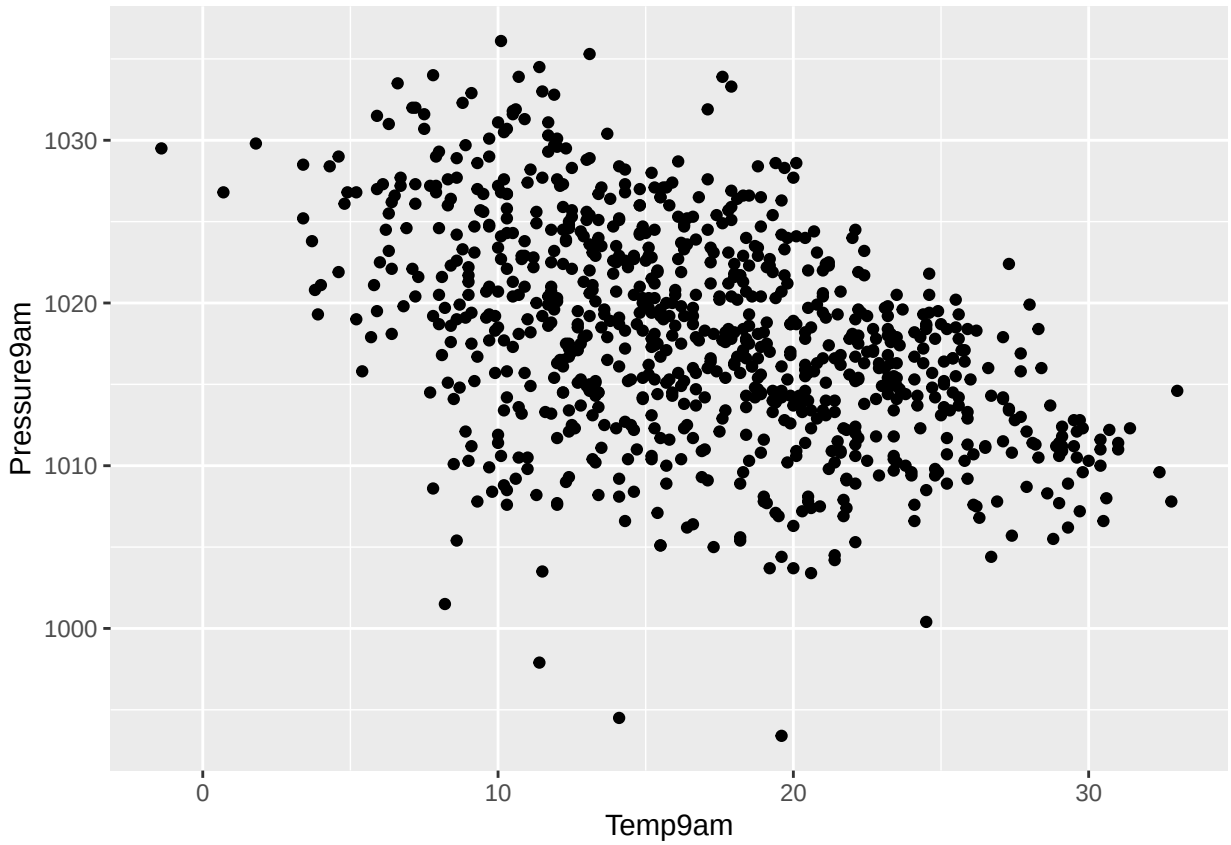
```
savedir = 'results'
if (!dir.exists(savedir)) dir.create(savedir)
ggsave(paste0(savedir, "/Ejercicio1.pdf"), plot = grafico3+geom_point())
```

```
## Saving 6.5 x 4.5 in image
```

2. Ejercicio 2

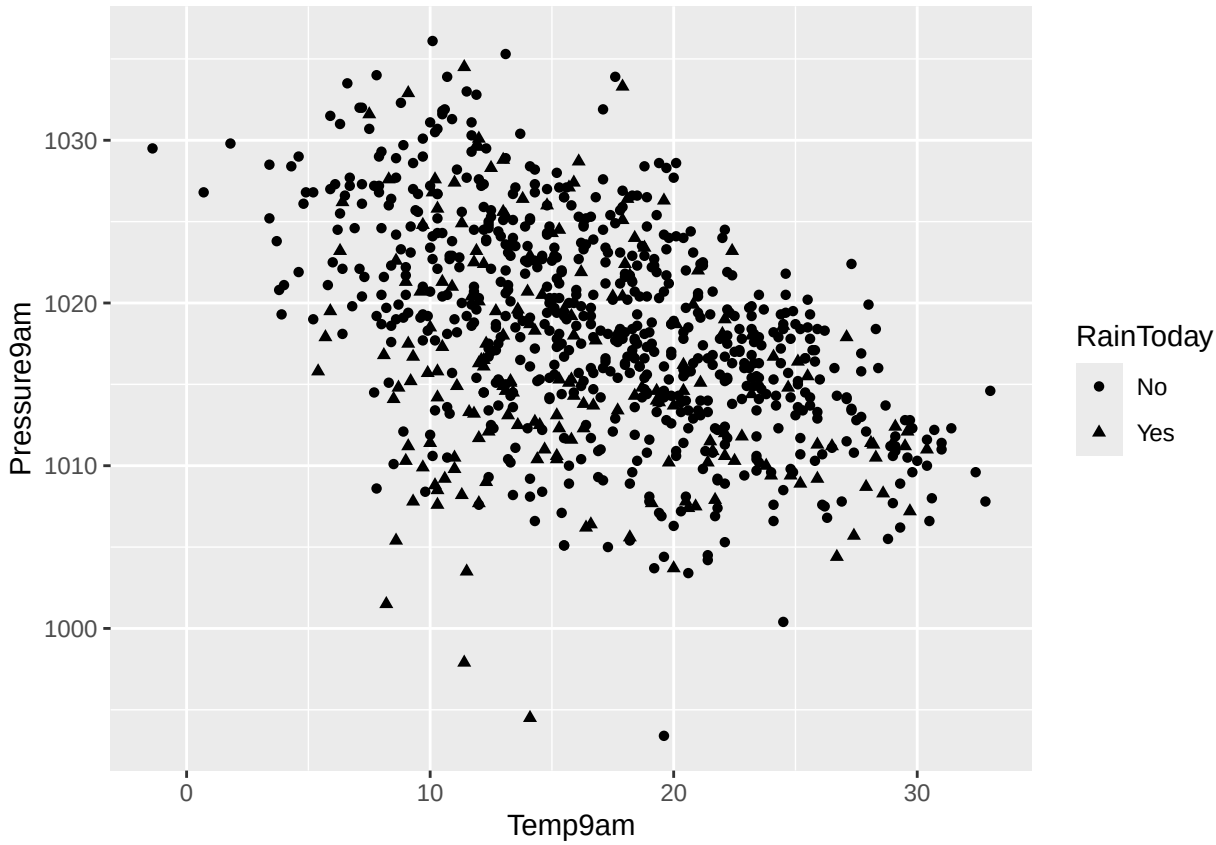
1. Utilizando ggplot haz un grafico de dispersión en el que representes las variables Temp9am y Pressure9am en los ejes x e y respectivamente.

```
p2.1 <- ggplot(ds, aes(x=Temp9am, y=Pressure9am)) + geom_point()
p2.1
```



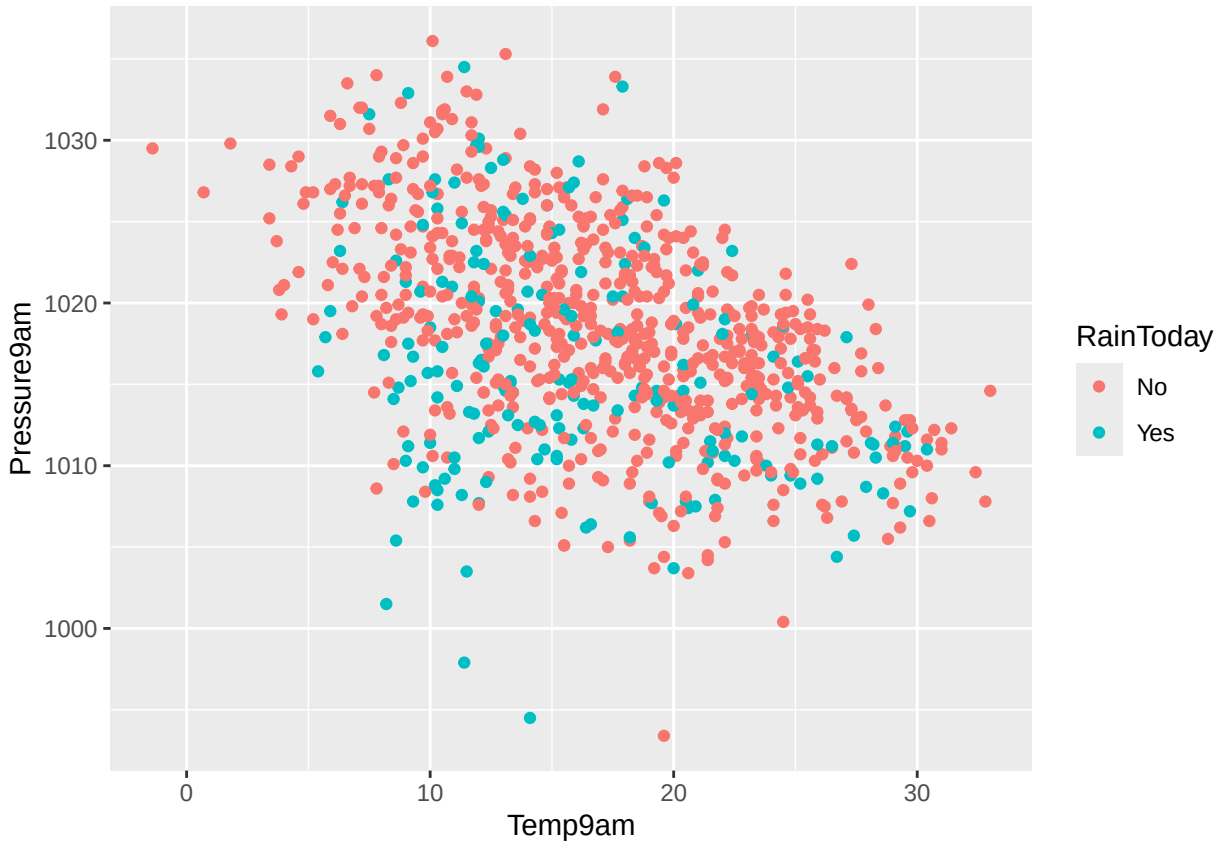
2. Modifica el gráfico anterior para incluir información categórica proporcionada por la variable RainToday con la forma del punto.

```
p2.2 <- ggplot(ds, aes(x=Temp9am, y=Pressure9am, shape=RainToday)) + geom_point()
p2.2
```



3. Modifica el gráfico anterior para incluir información categórica proporcionada por la variable RainToday con el color del punto. ¿Con qué representación (color o forma) se observa mejor la información que introduce la variable RainToday?

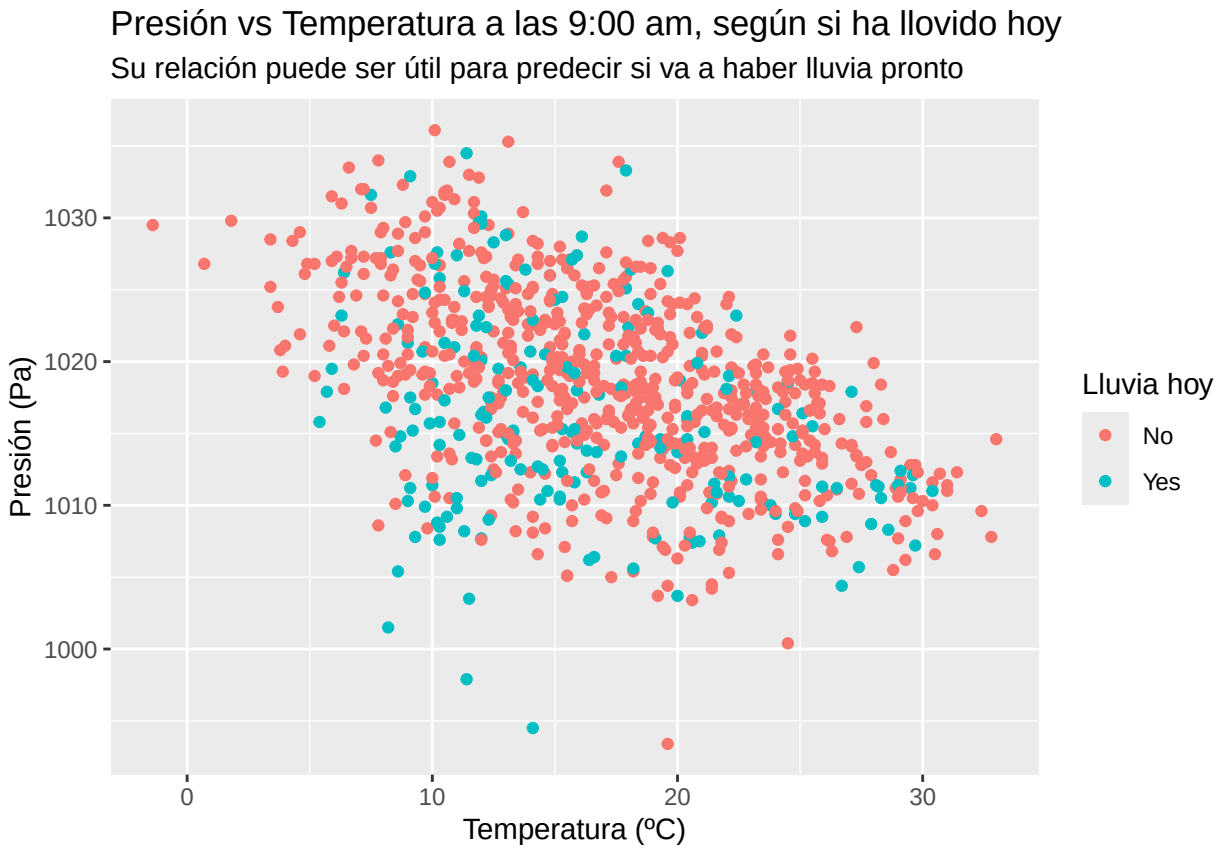
```
p2.3 <- ggplot(ds, aes(x=Temp9am, y=Pressure9am, colour=RainToday)) + geom_point()
p2.3
```



Se observa mejor la información de `RainToday` con la representación de **color**. Hay muchos puntos que se superponen, y con la representación de formas no se aprecia bien la distinción cagtegórica.

4. Añade títulos explicativos al gráfico anterior (debe aparece un título, subtítulo, leyendas e información de las variables representadas en los ejes).

```
p2.4 <- p2.3 + labs(
  title='Presión vs Temperatura a las 9:00 am, según si ha llovido hoy',
  subtitle='Su relación puede ser útil para predecir si va a haber lluvia pronto',
  colour='Lluvia hoy',
  x='Temperatura (ºC)',
  y='Presión (Pa)'
)
p2.4
```



5. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio2.pdf.

```
savedir = 'results'
if (!dir.exists(savedir)) dir.create(savedir)
ggsave(paste0(savedir, "/Ejercicio2.pdf"), plot = p2.4)
```

```
## Saving 6.5 x 4.5 in image
```

3. Ejercicio 3

1. Carga el fichero iris.tidy.Rdata utilizando lo aprendido en la práctica 1.

```
load('data/iris_tidy.Rdata')
```

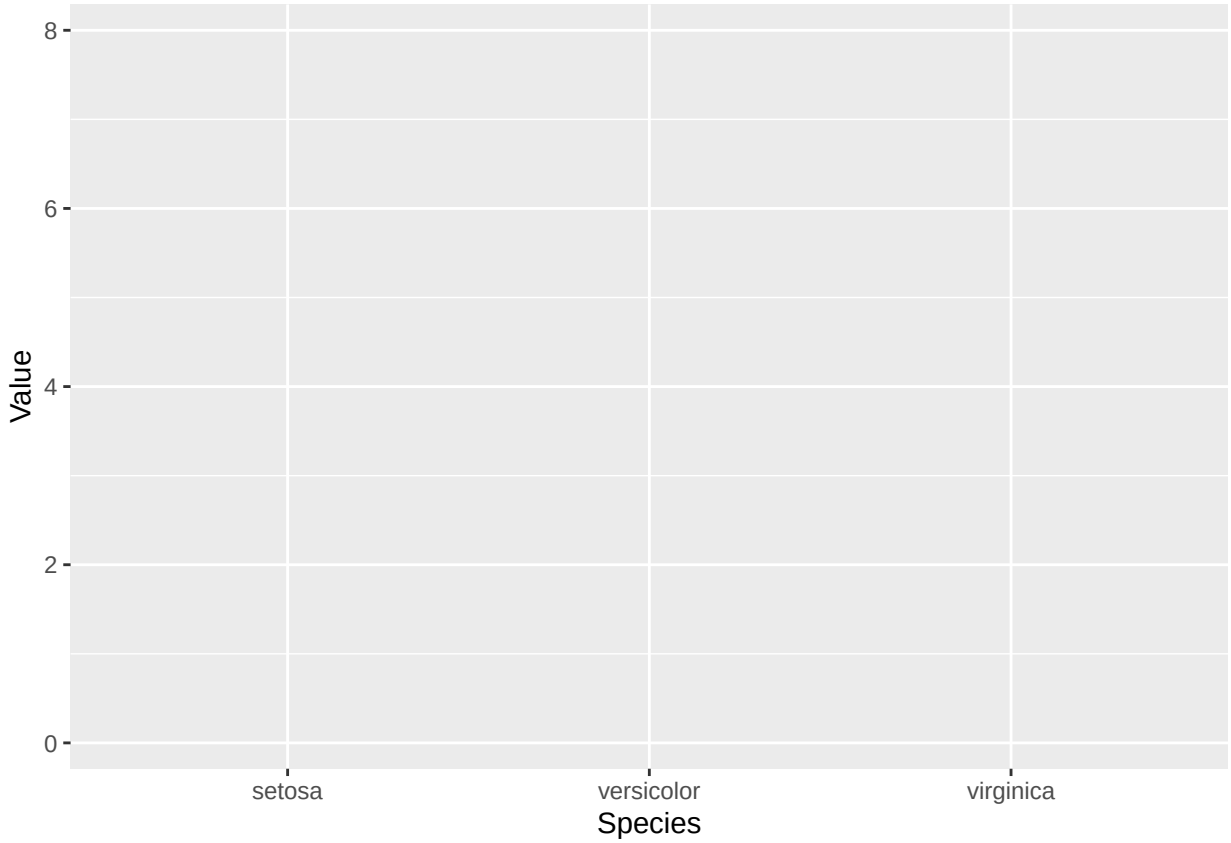
2. Utiliza la función str() para ver qué variables contiene el dataset.

```
str(iris.tidy)
```

```
## 'data.frame':    600 obs. of  4 variables:
##  $ Species: Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ Part   : Factor w/ 2 levels "Petal","Sepal": 2 2 2 2 2 2 2 2 2 2 ...
##  $ Measure: chr  "Length" "Length" "Length" "Length" ...
##  $ Value  : num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```

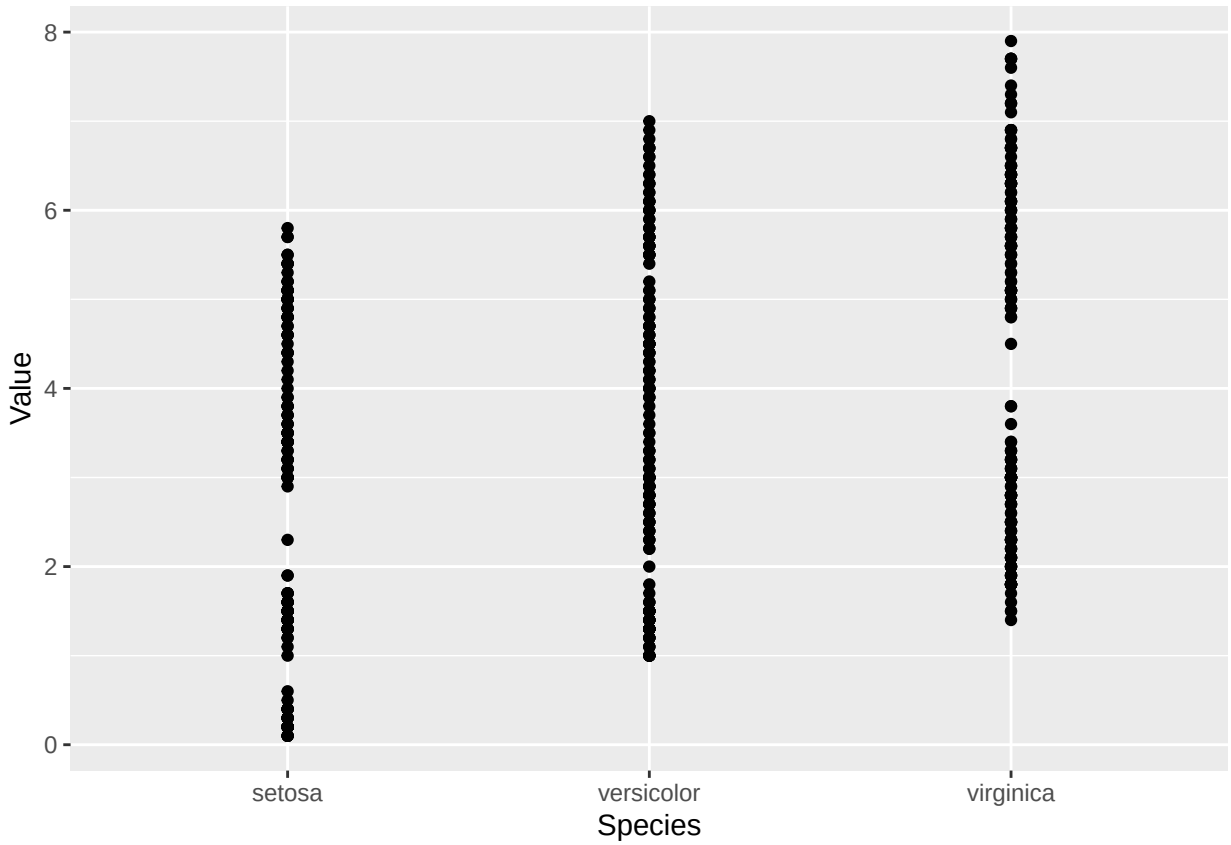
3. Crea un objeto ggplot denominado iris.grafico1 en el que esté definido el conjunto de datos iris.tidy alojado en el fichero iris.tidy.RData y un aesthetics en el que en el eje x esté definida la variable Species y en el eje y esté definida la variable Value.

```
iris.grafico1 <- ggplot(iris.tidy, aes(x=Species, y=Value))
iris.grafico1
```



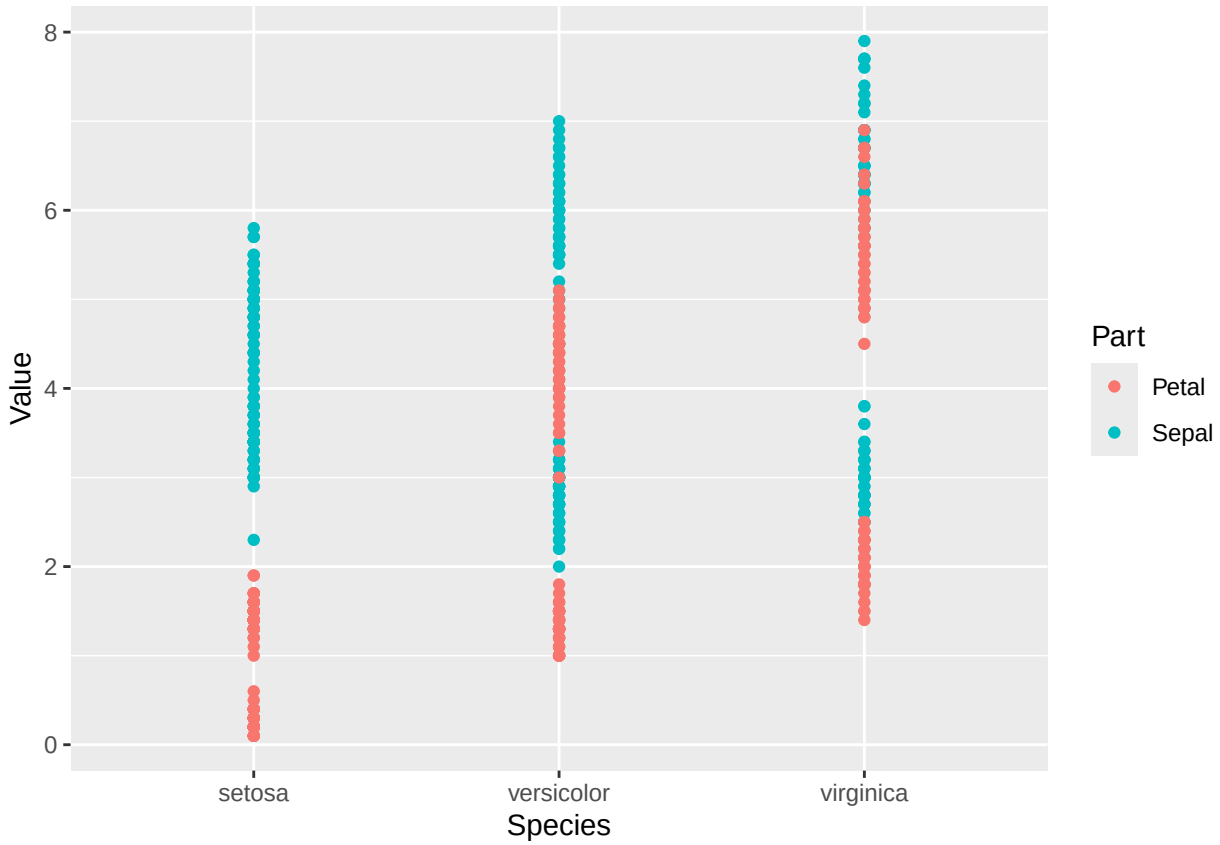
4. Añade una capa que defina el objeto geométrico necesario para construir un gráfico de dispersión de las variables Species y Value.

```
iris.grafico1 + geom_point()
```



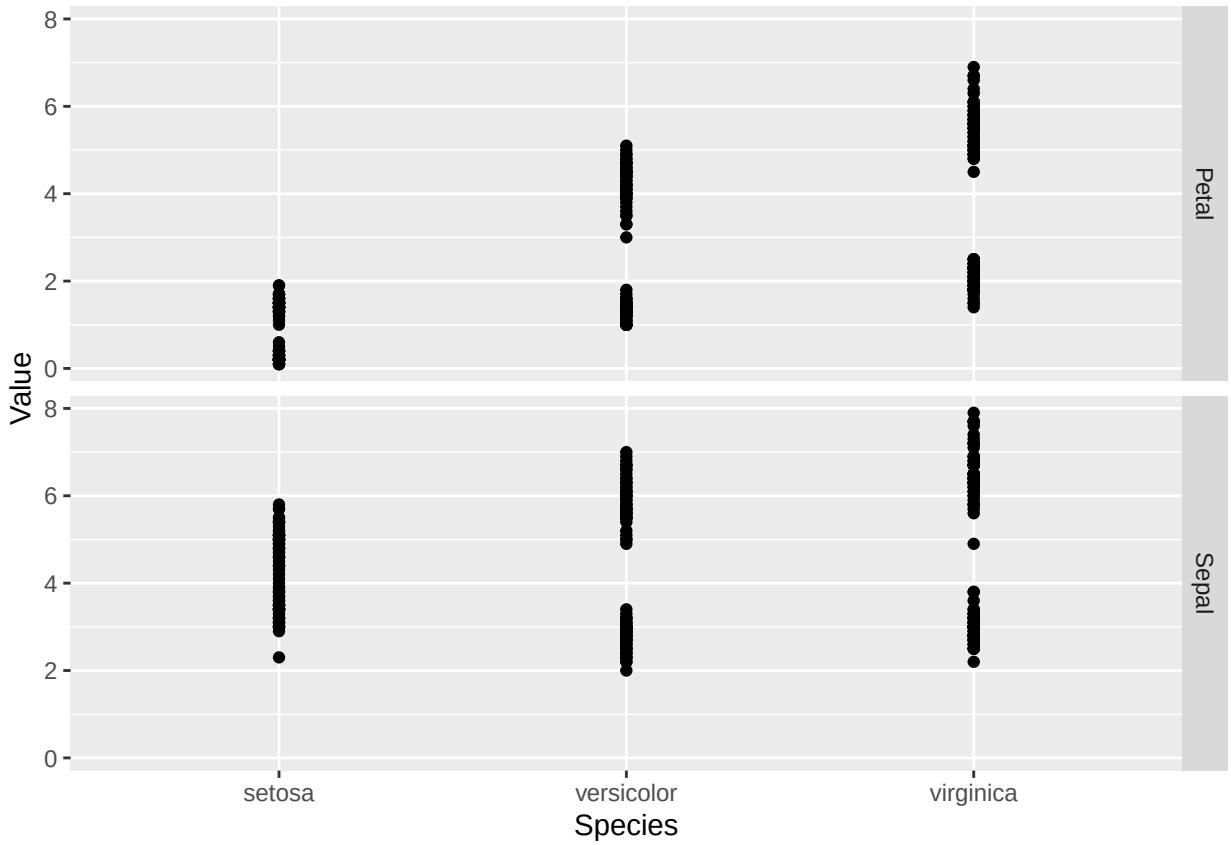
5. Modifica el aesthetics de iris.grafico1 para visualizar la variable categórica Part y almacénalo en iris.grafico2. A partir del objeto iris.grafico2, representa un gráfico de dispersión en el que se muestren los puntos dados por las variables Species y Value, y el color del punto se corresponda con el valor de la variable Part.

```
iris.grafico2 <- ggplot(iris.tidy, aes(x=Species, y=Value, colour=Part))
iris.grafico2 + geom_point()
```

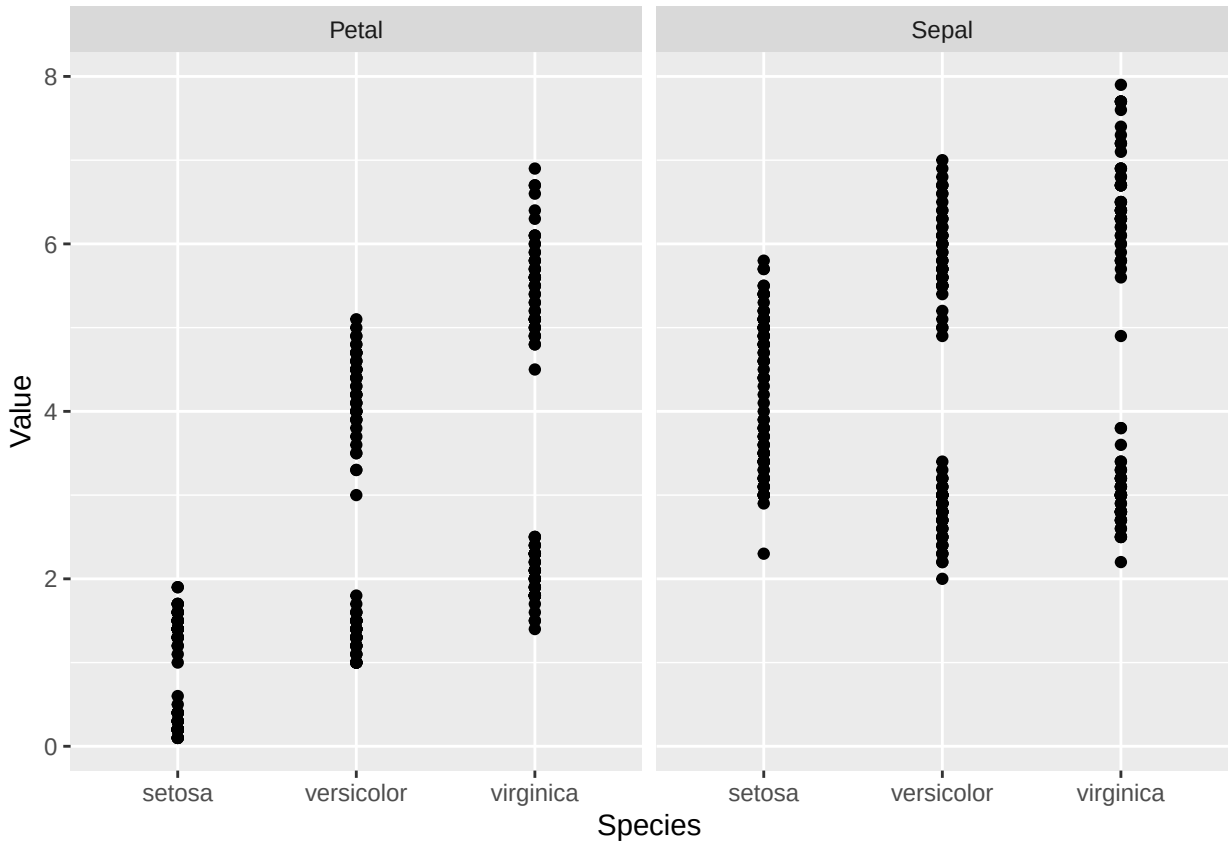


6. Incluye información de la variable Measure haciendo dos gráficos de dispersión (dispuestos en filas) con facet_grid(), como en el apartado de introducción, para los dos valores que toma la variable Measure. Prueba a cambiar la disposición de los gráficos para que sea en columnas ¿Qué disposición, en filas o en columnas, permite comparar mejor los valores de las dos variables?

```
iris.grafico1 + geom_point() + facet_grid(Part~.)
```



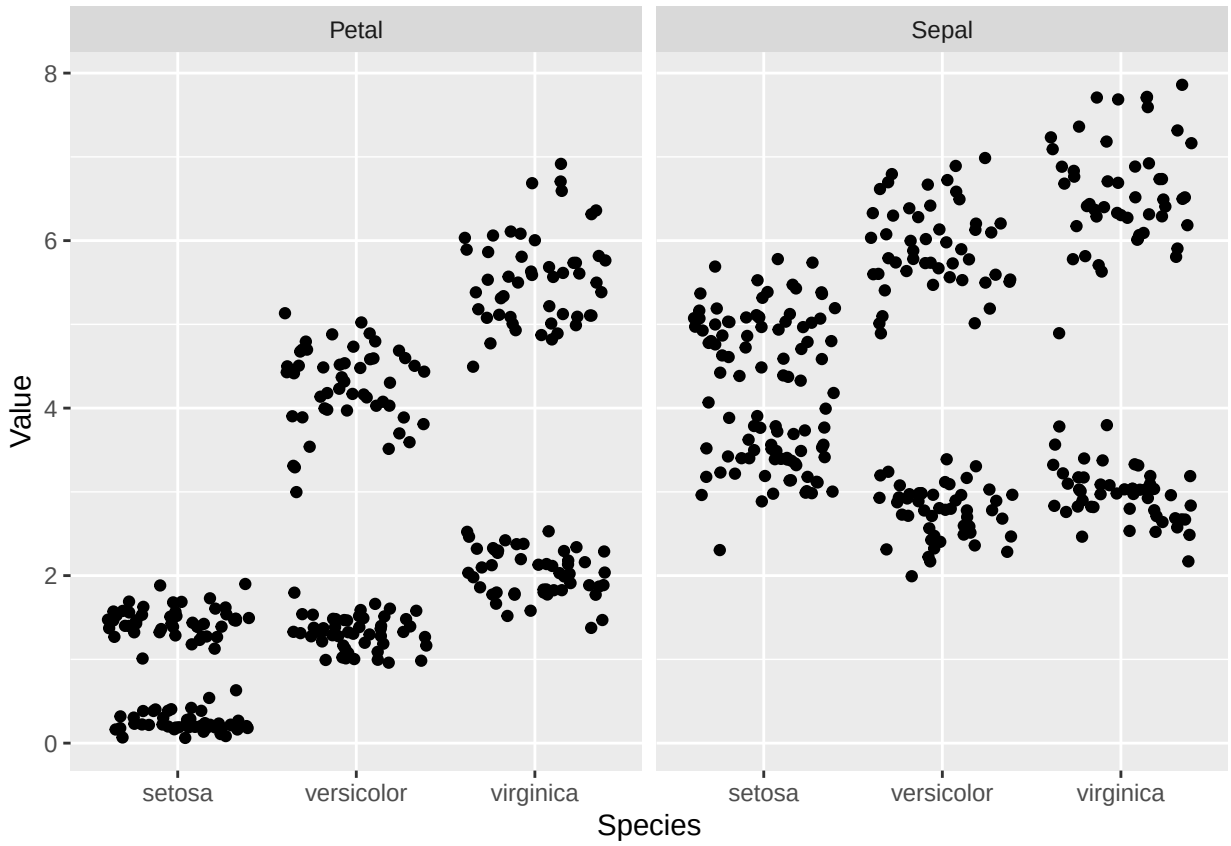

```
iris.grafico1 + geom_point() + facet_grid(.~Part)
```



Es más informativa la disposición en columnas, porque comparten el eje Y, y eso nos permite comparar visualmente de forma directa la distribución de los puntos entre las dos gráficas en función de la variable Value.

7. Cambia ahora la capa geom_point() del gráfico anterior por la capa geom_jitter(). ¿Qué diferencia observas?

```
iris.grafico1 + geom_jitter() + facet_grid(.~Part)
```



Es más fácil diferenciar los *clusters* en que se agrupan los datos.

8. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio3.pdf.

```
ggsave('./results/Ejercicio3.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```

4. Ejercicio 4

1. Carga el fichero Ejercicio4_Data.Rdata. Examina las variables que tiene dicho dataset.

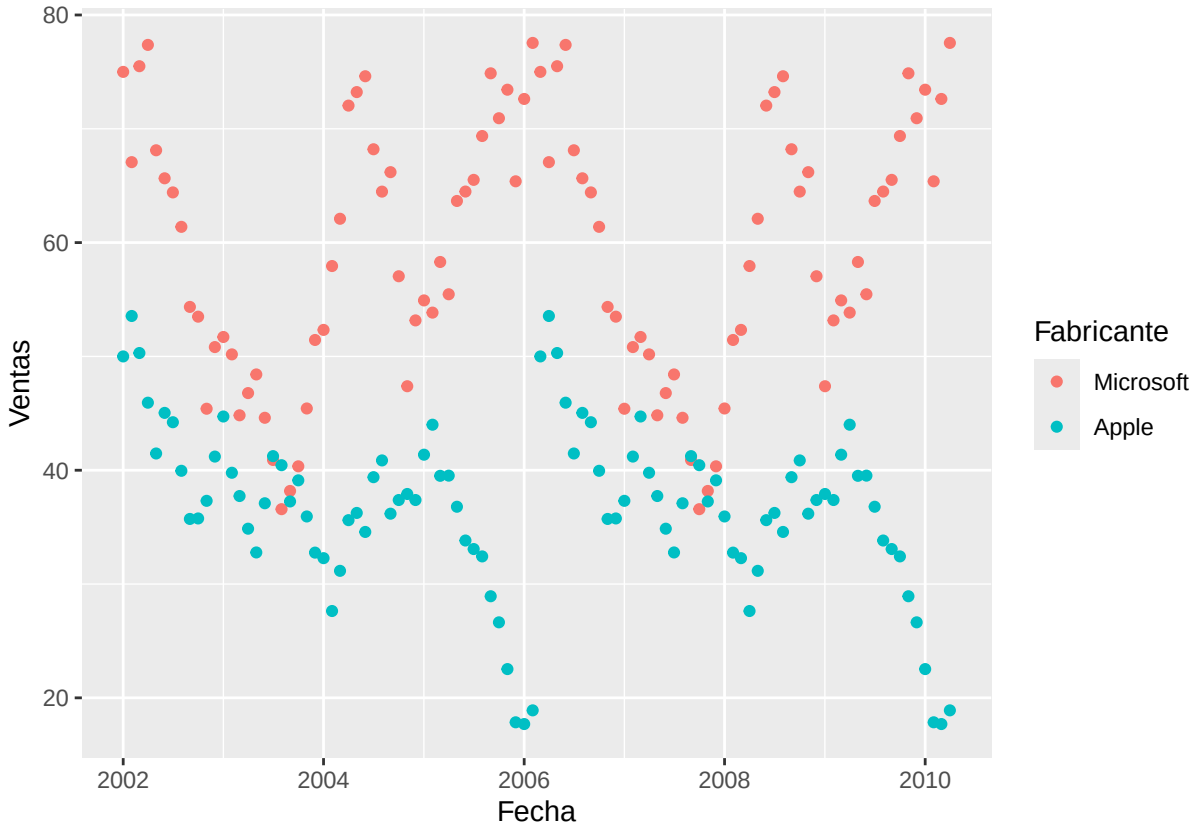
```
load('./data/Ejercicio4_Data.Rdata')
```

```
str(DatosEjer4)
```

```
## 'data.frame':    200 obs. of  3 variables:
##  $ Fecha     : Date, format: "2002-01-01" "2002-02-01" ...
##  $ Fabricante: Factor w/ 2 levels "Microsoft","Apple": 1 1 1 1 1 1 1 1 1 1 ...
##  $ Ventas    : num  75 67.1 75.5 77.4 68.1 ...
```

2. Representa un gráfico de puntos, en el que se muestre la fecha en el eje x y las ventas en el eje y. Queremos que los datos de cada fabricante sean de un color distinto. ¿Es este gráfico válido para evaluar la evolución de las ventas de cada fabricante?

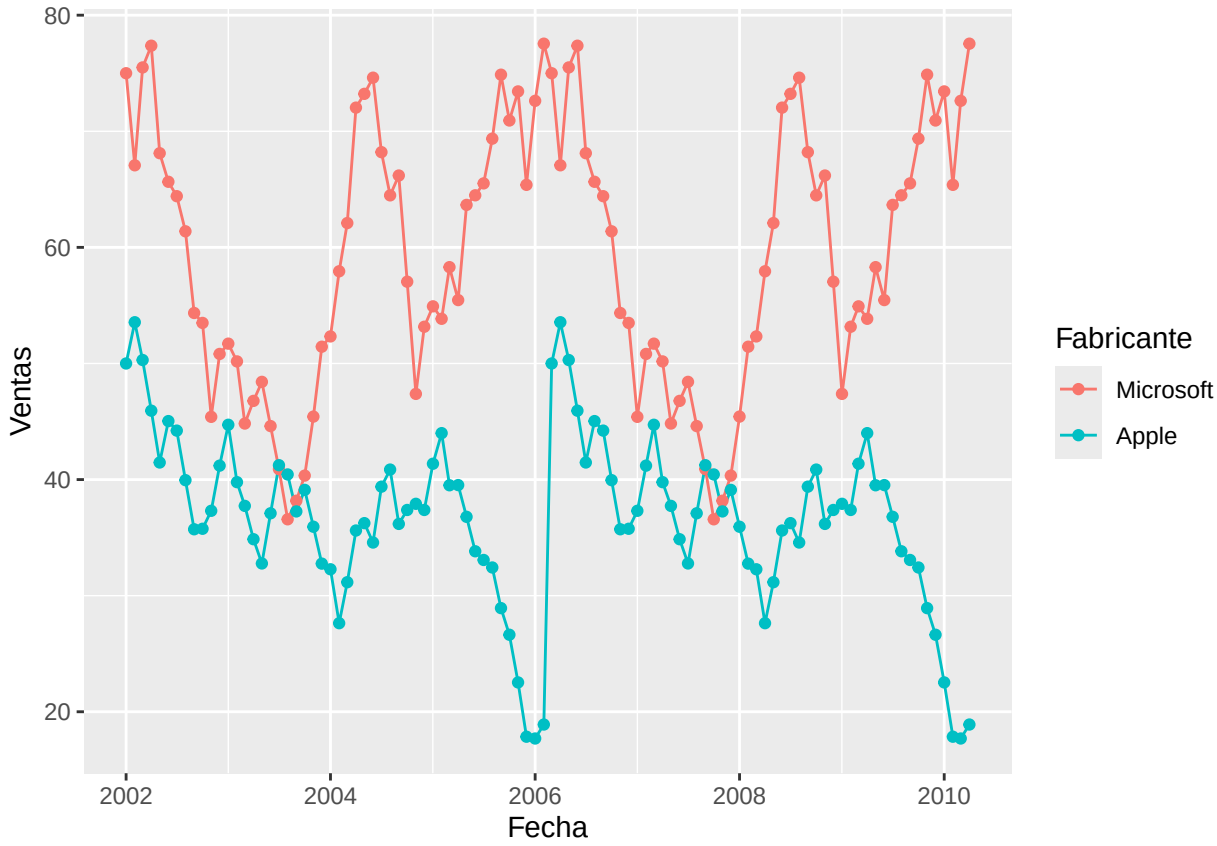
```
p4.2 <- ggplot(DatosEjer4, aes(x=Fecha, y=Ventas, colour=Fabricante))
p4.2 + geom_point()
```



Para evaluar la evolución de las ventas, sería más apropiado dibujar líneas en vez de puntos. Un gráfico como este contiene debasiados puntos como para apreciar bien la evolución, mientras que no se resalta la relación entre puntos consecutivos.

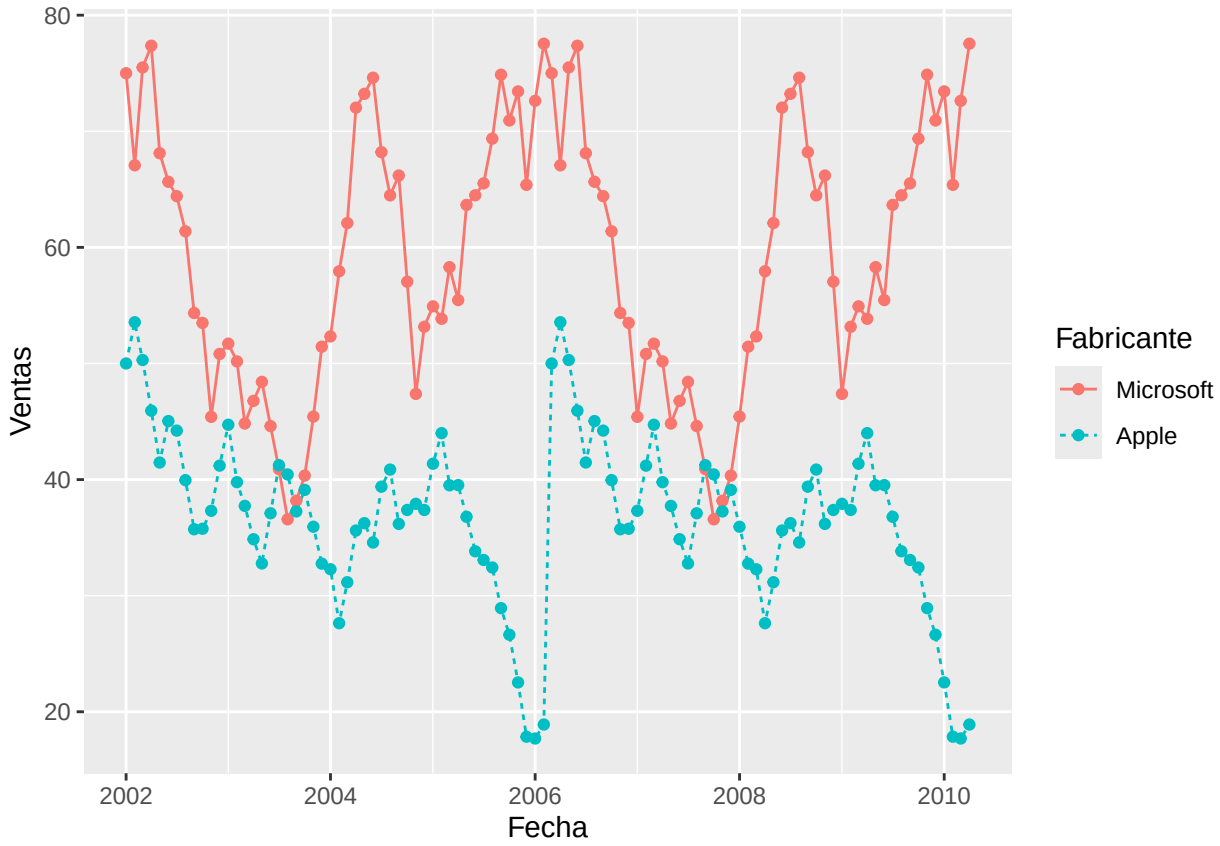
3. Representa un gráfico como el anterior en el que se muestre la línea que une los puntos que antes has representado.

```
p4.2 + geom_line() + geom_point()
```



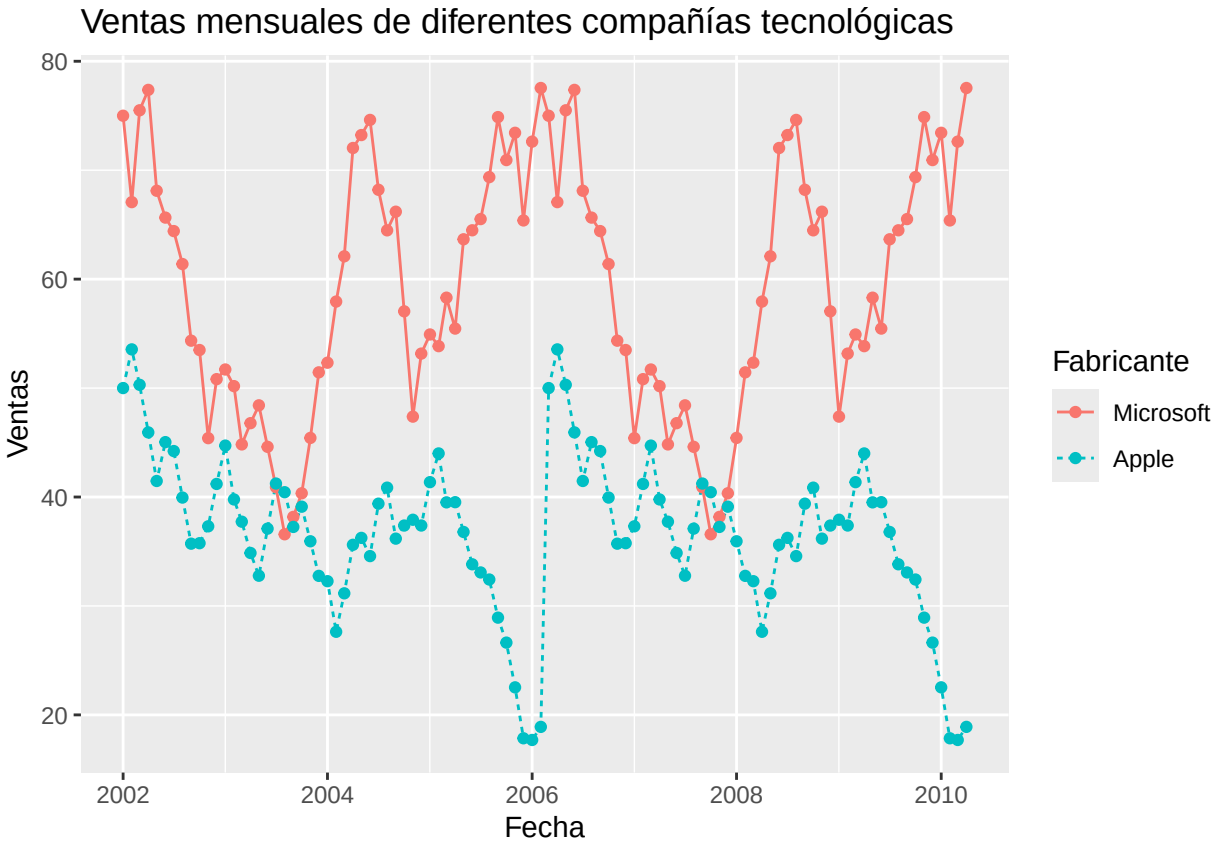
4. Modifica el gráfico anterior para que la tendencia de cada fabricante este trazada con un tipo de línea diferente.

```
p4.2 + geom_line(aes(linetype = Fabricante)) + geom_point()
```



5. Añade el siguiente título al gráfico "Ventas mensuales de diferentes compañías tecnológicas".

```
p4.5 <- p4.2 + geom_line(aes(linetype = Fabricante)) + geom_point() + ggtitle('Ventas mensuales de difer
p4.5
```



6. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio4.pdf.

```
ggsave('./results/Ejercicio4.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```

5. Ejercicio 5

1. Carga el fichero Experimento.Rdata. Examina las variables que tiene dicho dataset.

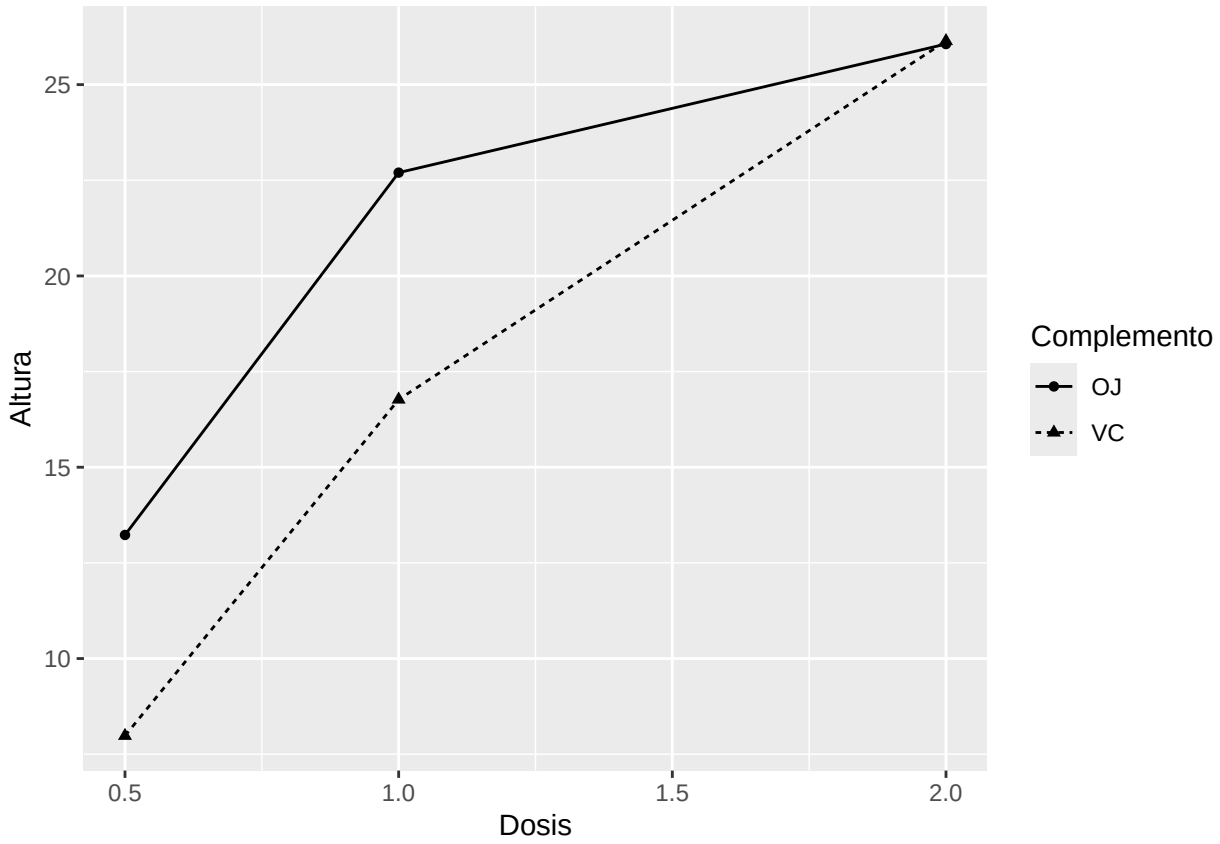
```
load('./data/Experimento.Rdata')
```

```
str(Experimento)
```

```
## 'data.frame':    6 obs. of  4 variables:
##  $ Complemento : Factor w/ 2 levels "OJ","VC": 1 1 1 2 2 2
##  $ Dosis       : num  0.5 1 2 0.5 1 2
##  $ Altura      : num  13.23 22.7 26.06 7.98 16.77 ...
##  $ Error_Altura: num  4.46 3.91 2.66 2.75 2.52 ...
```

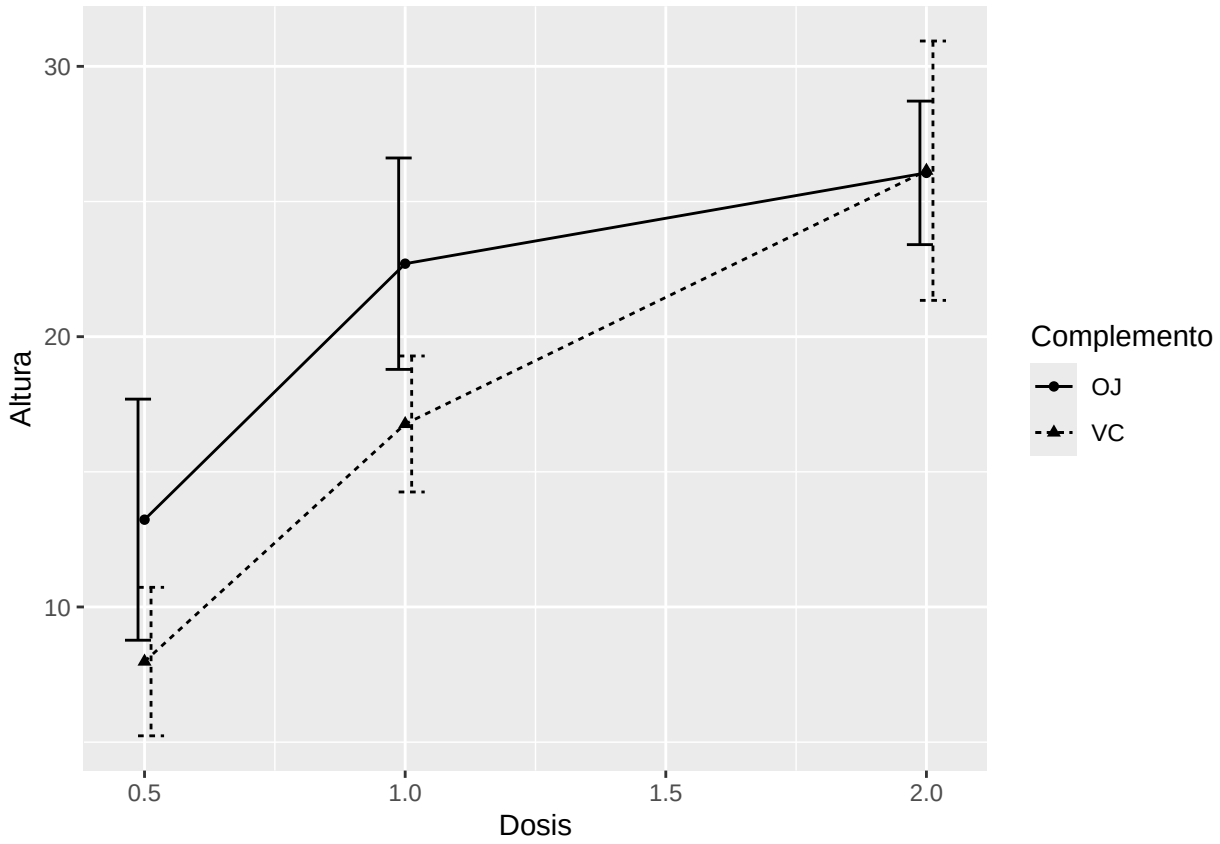
2. Representa un gráfico de puntos, en el que se muestre la Dosis en el eje x y la Altura en el eje y. Queremos que los datos de cada Complemento se representen en una línea diferente con diferentes trazos. Hazlo incluyendo las opciones de tipo de línea y forma del punto dentro del aes() de la capa ggplot.

```
p5.2 <- ggplot(Experimento, aes(x=Dosis, y=Altura, shape=Complemento, linetype= Complemento))
p5.2 + geom_point() + geom_line()
```



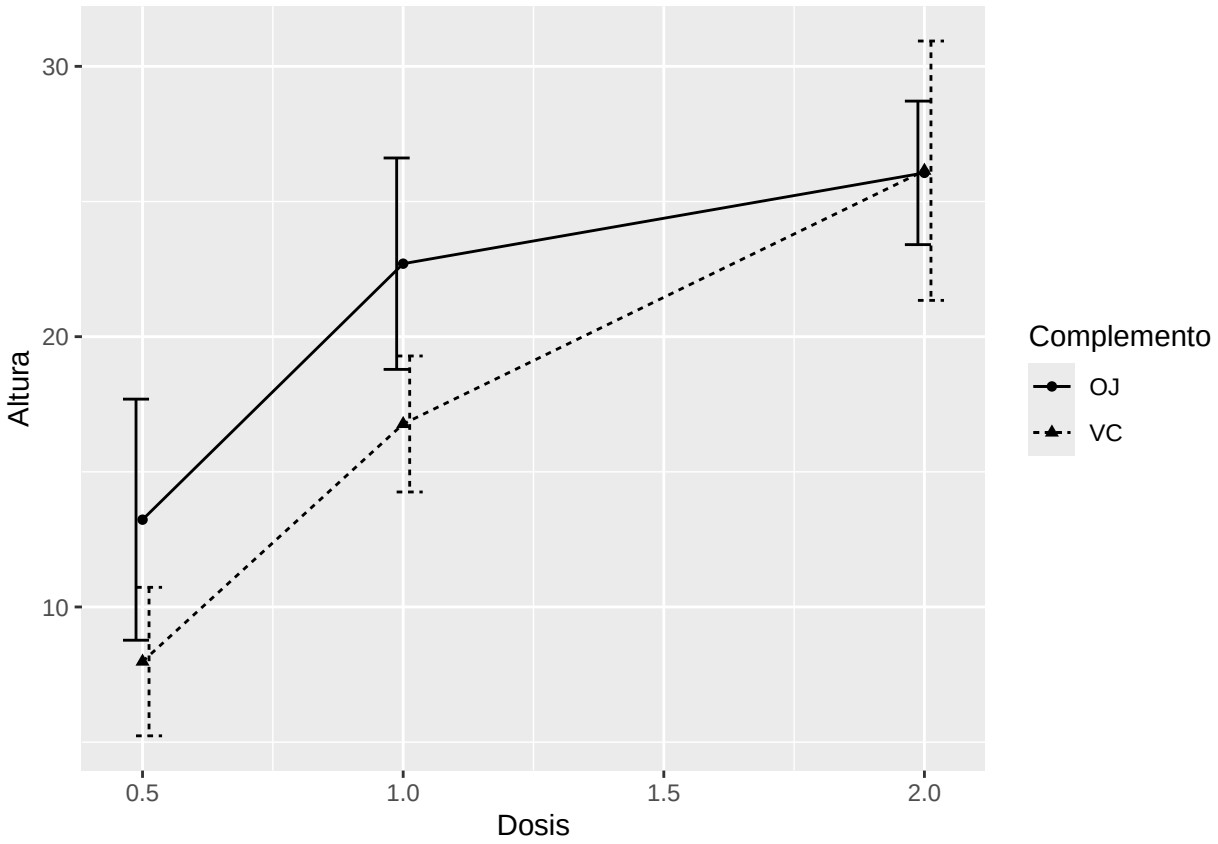
3. Crea otro gráfico añadiendo al gráfico anterior barras de error en cada punto. El error viene dado por la variable Error_Altura.

```
p5.2 + geom_point() + geom_line() + geom_errorbar(aes(ymin=Altura-Error_Altura, ymax=Altura+Error_Altura
```



4. Crea otro gráfico, como el anterior (idéntico), pero en este caso no puedes incluir el tipo de línea y el tipo de punto en aes() de la capa ggplot. Además queremos que la paleta de colores sea en tonos de rojos (scale_color_brewer).

```
p5.4 <- ggplot(Experimento, aes(x=Dosis, y=Altura))
p5.4 +
  geom_point(aes(shape=Complemento)) +
  geom_line(aes(linetype=Complemento)) +
  geom_errorbar(aes(ymin=Altura-Error_Altura, ymax=Altura+Error_Altura, linetype=Complemento), position=
```



5. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio5.pdf.

```
ggsave('./results/Ejercicio5.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```

6. Ejercicio 6

El fichero iceRiver.RData contiene información del caudal de dos ríos islandeses medidos a diarios durante 3 años. Puedes obtener información detallada de las variables usando > ?tseries::ice.river

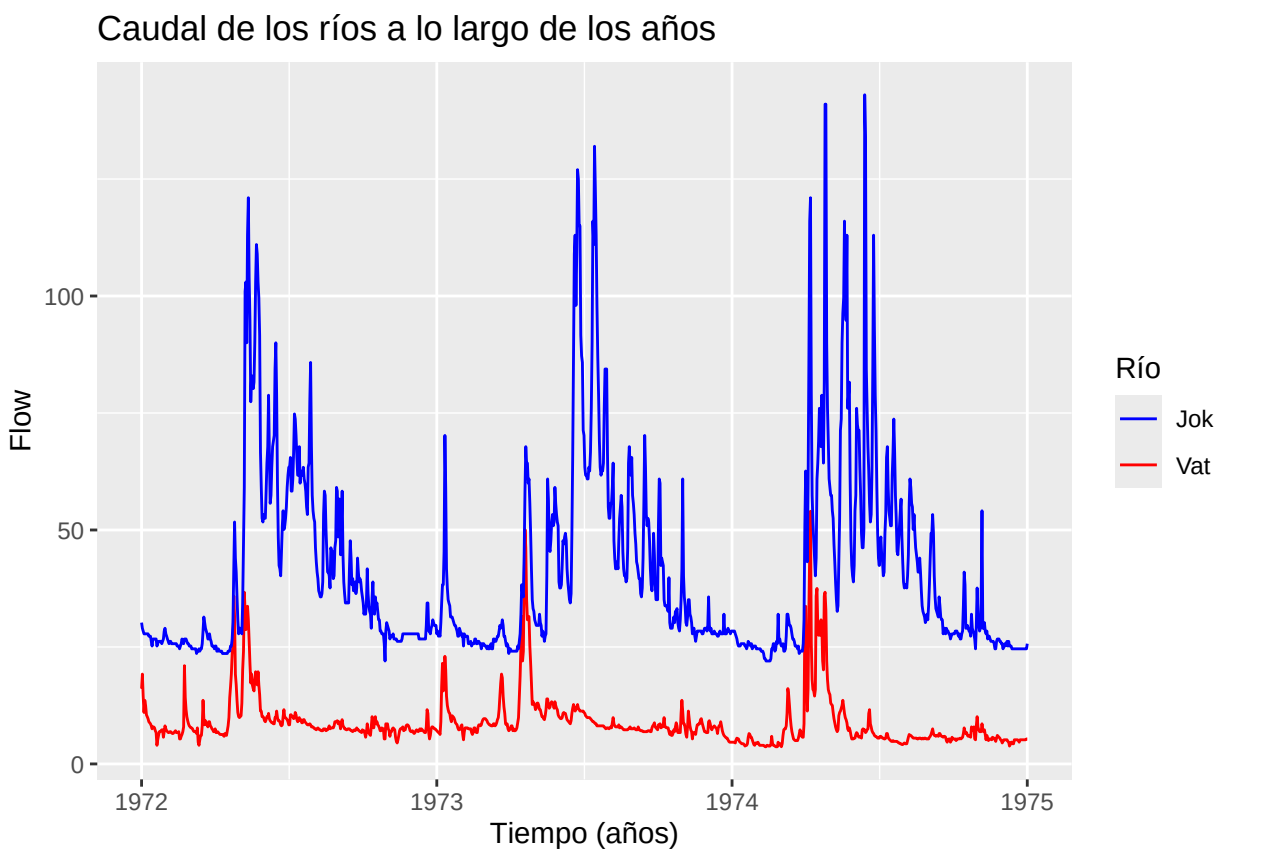
```
load('./data/iceRiver.RData')
str(ice.river.df)
```

```
## 'data.frame':    1096 obs. of  5 variables:
##  $ flow.vat: num  16.1 19.2 14.5 11 13.6 12.5 10.5 10.1 9.68 9.02 ...
##  $ flow.jok: num  30.2 29 28.4 27.8 27.8 27.8 27.8 27.8 27.8 27.3 ...
##  $ prec    : num  8.1 4.4 7 0 0 0 1.9 1.2 0 0.1 ...
##  $ temp    : num  0.9 1.6 0.1 0.6 2 0.8 1.4 1.3 2.2 0.1 ...
##  $ time    : num  1972 1972 1972 1972 1972 ...
```

1. Representa el caudal de ambos ríos a lo largo del período considerado coloreando una serie (flow.vat) en color rojo y la otra en color azul. Utiliza la función labs para enriquecer el gráfico.

```
p6.1 <- ggplot(ice.river.df, aes(x=time))
p6.3 <- p6.1 +
  geom_line(aes(y=flow.vat, color="Vat")) +
  geom_line(aes(y=flow.jok, color="Jok")) +
  scale_color_manual(values = c("Vat" = "red", "Jok" = "blue")) +
```

```
  labs(
    title='Caudal de los ríos a lo largo de los años',
    y='Flow',
    x='Tiempo (años)',
    colour='Río'
    )
p6.3
```




```
ggsave('./results/Ejercicio6.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```

7. Ejercicio 7

1. Carga el fichero weatherAUS_distributions.RData.

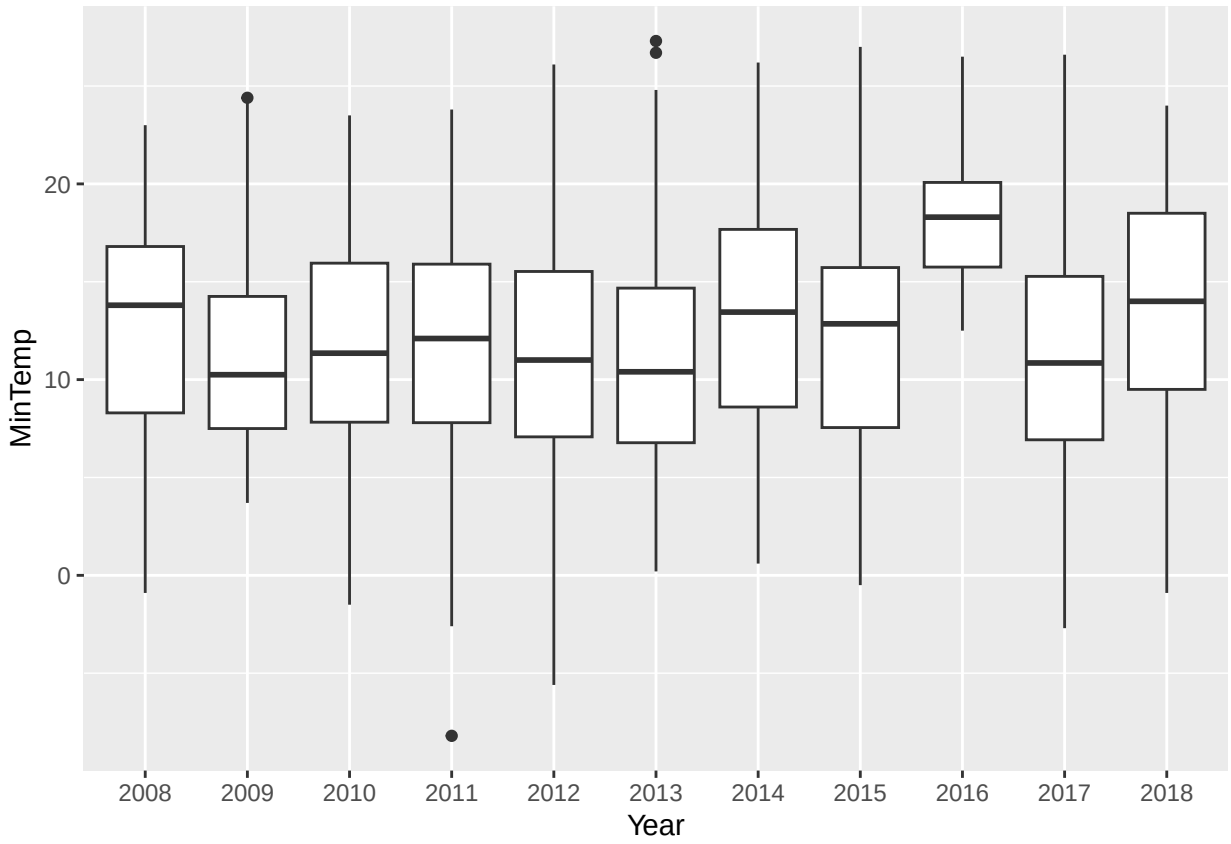
```
load('./data/weatherAUS_distributions.RData')
str(ds)
```

```
## 'data.frame':    863 obs. of  24 variables:
##  $ Year         : Factor w/ 11 levels "2008","2009",..: 2 7 3 6 5 10 10 7 7 2 ...
##  $ Location     : chr  "Richmond" "Albury" "Launceston" "Sale" ...
##  $ MinTemp      : num  14.2 13.9 0.4 0.2 10.2 9 8.6 24 12.4 24.4 ...
##  $ MaxTemp      : num  29.8 27.7 13.1 15.1 20.7 17.2 23.9 34.2 18 31.9 ...
##  $ Rainfall     : num  0.2 1.4 0 0.2 0 1 0 0 2 18.4 ...
##  $ Evaporation  : chr  "12.2" NA NA "1.2" ...
##  $ Sunshine     : chr  NA NA NA "7.3" ...
```

```
##  $ WindGustDir  : chr  "NE" "W" "S" "NW" ...
##  $ WindGustSpeed: int  28 37 19 17 NA 44 63 41 NA 31 ...
##  $ WindDir9am   : chr  NA "ENE" NA "WNW" ...
##  $ WindDir3pm   : chr  "E" "NW" "SSE" "NNW" ...
##  $ WindSpeed9am : int  0 6 0 9 6 22 13 15 6 11 ...
##  $ WindSpeed3pm : int  11 22 4 7 13 30 39 15 35 17 ...
##  $ Humidity9am  : int  92 74 98 93 64 71 62 71 84 83 ...
##  $ Humidity3pm  : int  36 42 57 57 40 63 22 56 61 68 ...
##  $ Pressure9am  : num  1017 1008 1028 1024 1025 ...
##  $ Pressure3pm  : num  1014 1007 1026 1021 1020 ...
##  $ Cloud9am     : int  NA NA NA 2 5 3 2 6 7 6 ...
##  $ Cloud3pm     : int  NA 5 NA 3 7 8 1 3 3 6 ...
##  $ Temp9am      : num  18.3 20.9 4.3 3.7 13 12.8 15.4 29.7 15.3 27.9 ...
##  $ Temp3pm      : num  29.5 26.4 11.9 14.3 18.7 14.6 23.5 32.1 17.5 30.9 ...
##  $ RainToday    : chr  "No" "Yes" "No" "No" ...
##  $ RISK_MM      : num  0 0 0.4 0 0 0.2 0 0 1.6 24.2 ...
##  $ RainTomorrow : chr  "No" "No" "No" "No" ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Date = col_date(format = ""),
##   ..   Location = col_character(),
##   ..   MinTemp = col_double(),
##   ..   MaxTemp = col_double(),
##   ..   Rainfall = col_double(),
##   ..   Evaporation = col_character(),
##   ..   Sunshine = col_character(),
##   ..   WindGustDir = col_character(),
##   ..   WindGustSpeed = col_integer(),
##   ..   WindDir9am = col_character(),
##   ..   WindDir3pm = col_character(),
##   ..   WindSpeed9am = col_integer(),
##   ..   WindSpeed3pm = col_integer(),
##   ..   Humidity9am = col_integer(),
##   ..   Humidity3pm = col_integer(),
##   ..   Pressure9am = col_double(),
##   ..   Pressure3pm = col_double(),
##   ..   Cloud9am = col_integer(),
##   ..   Cloud3pm = col_integer(),
##   ..   Temp9am = col_double(),
##   ..   Temp3pm = col_double(),
##   ..   RainToday = col_character(),
##   ..   RISK_MM = col_double(),
##   ..   RainTomorrow = col_character()
##   .. )
```

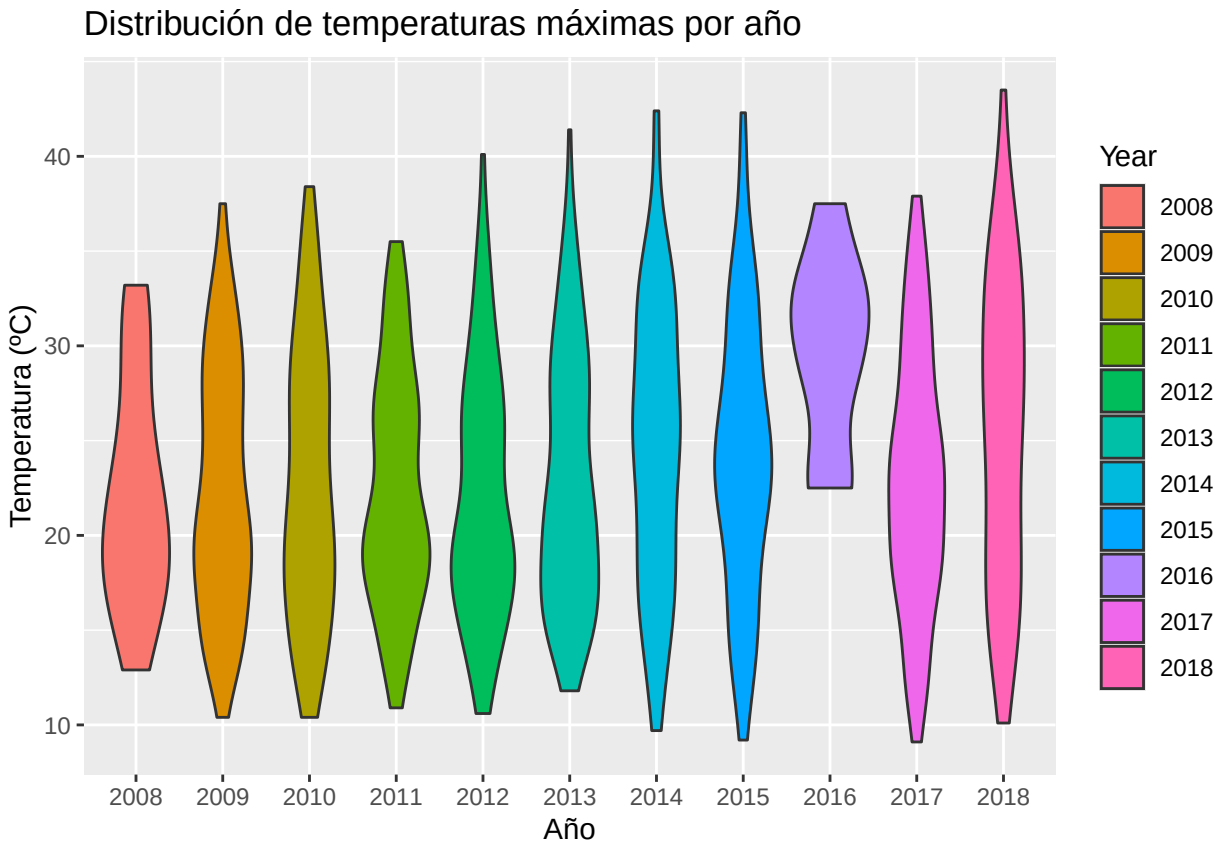
2. Crea un gráfico en el que estén los boxplots de la variable MinTemp para cada uno de los años presentes en la variable Year del dataset.

```
p7.2 <- ggplot(ds, aes(x=Year, y=MinTemp))
p7.2 + geom_boxplot()
```



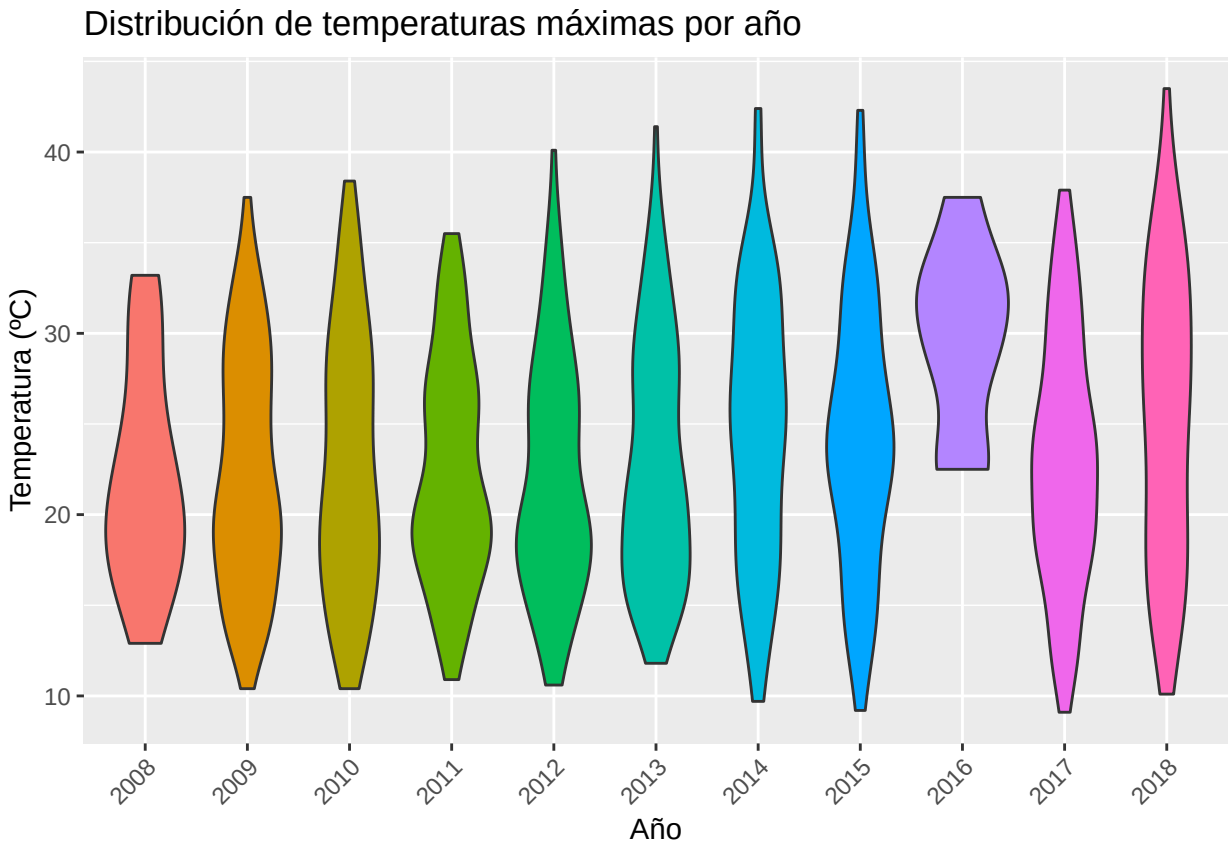
3. Crea un gráfico en el que estén los gráficos de violín de la variable MaxTemp para cada uno de los años presentes en la variable Year del dataset. Añade en el mismo gráfico una capa de etiquetas de título (Distribución de temperaturas máximas por año), eje x (Año) y eje y (Temperatura (ºC)). Colorea el interior de los violines según la la variable Year.

```
p7.3 <- ggplot(ds, aes(x=Year, y=MaxTemp))
p7.3 + geom_violin(aes(fill=Year)) +
  labs(
    title="Distribución de temperaturas máximas por año",
    x='Año',
    y='Temperatura (ºC)'
  )
```



4. En el gráfico anterior elimina la leyenda y coloca los años en el eje x a 45 grados de inclinación. Busca información sobre cómo hacer esto.

```
p7.3 +
  geom_violin(aes(fill=Year)) +
  labs(
    title = "Distribución de temperaturas máximas por año",
    x = "Año",
    y = "Temperatura (ºC)"
  ) +
  theme(
    legend.position = "none",
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
```




```
ggsave('./results/Ejercicio7.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```

8. Ejercicio 8

1. Descarga de la url "http://assets.datacamp.com/blog_assets/chol.txt" el dataset de Datacamp que utilizarás para este ejercicio y cárgalo en un dataframe.

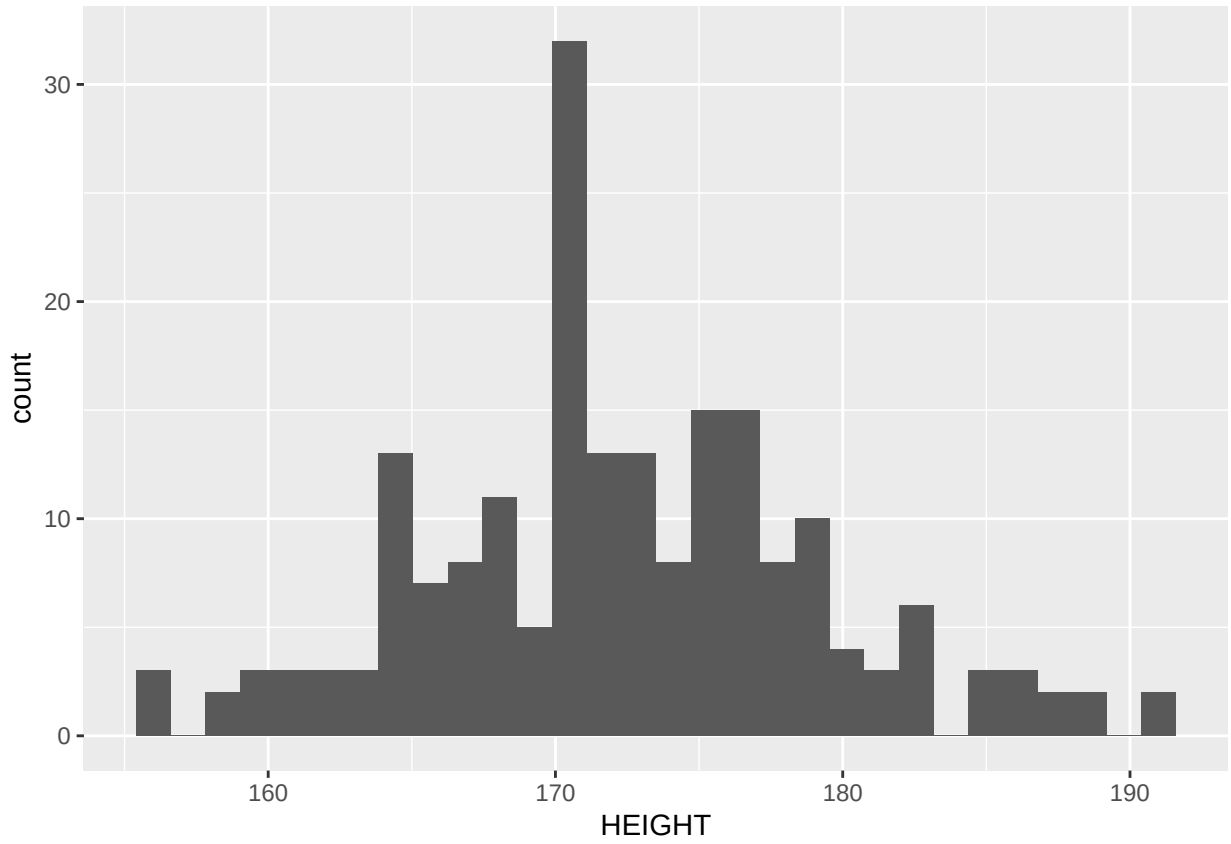
```
url <- "http://assets.datacamp.com/blog_assets/chol.txt"
df <- read.table(url, header = TRUE)
str(df)
```

```
## 'data.frame':    200 obs. of  7 variables:
##  $ AGE   : int  20 53 44 37 26 41 39 28 33 39 ...
##  $ HEIGHT: int  176 167 170 173 170 165 174 171 180 166 ...
##  $ WEIGHT: int  77 56 80 89 71 62 75 68 100 74 ...
##  $ CHOL  : int  195 250 304 178 206 284 232 152 209 150 ...
##  $ SMOKE : chr  "nonsmo" "sigare" "sigare" "nonsmo" ...
##  $ BLOOD : chr  "b" "o" "a" "o" ...
##  $ MORT  : chr  "alive" "dead" "dead" "alive" ...
```

2. Representa el histograma de la variable HEIGHT del dataframe cargado del fichero anterior.

```
p8.2 <- ggplot(df, aes(x=HEIGHT))
p8.2 + geom_histogram()
```

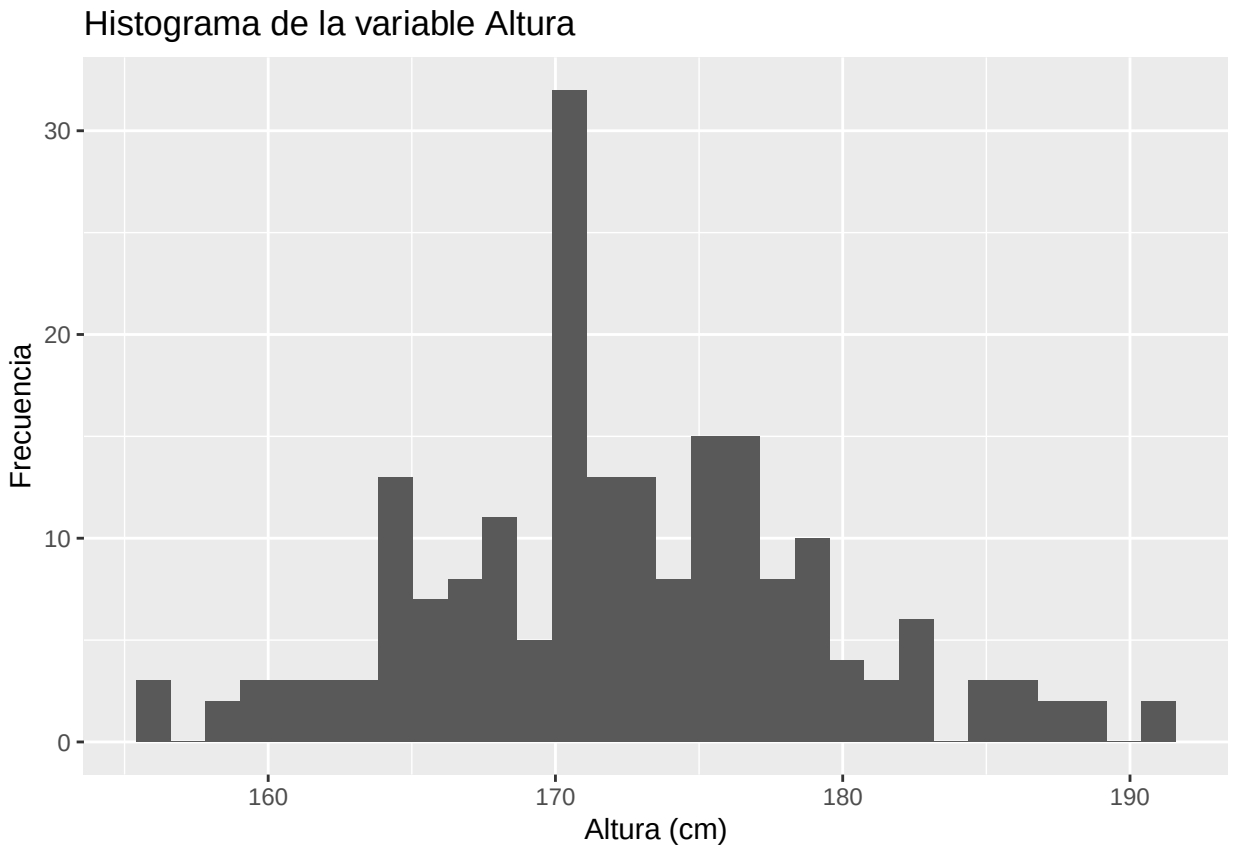
```
## `stat_bin()` using `bins = 30`. Pick better value `binwidth`.
```



3. Añade título (“Histograma de la variable Altura”), una etiqueta en el eje x (“Altura (cm)”) y una etiqueta en el eje y (“Frecuencia”).

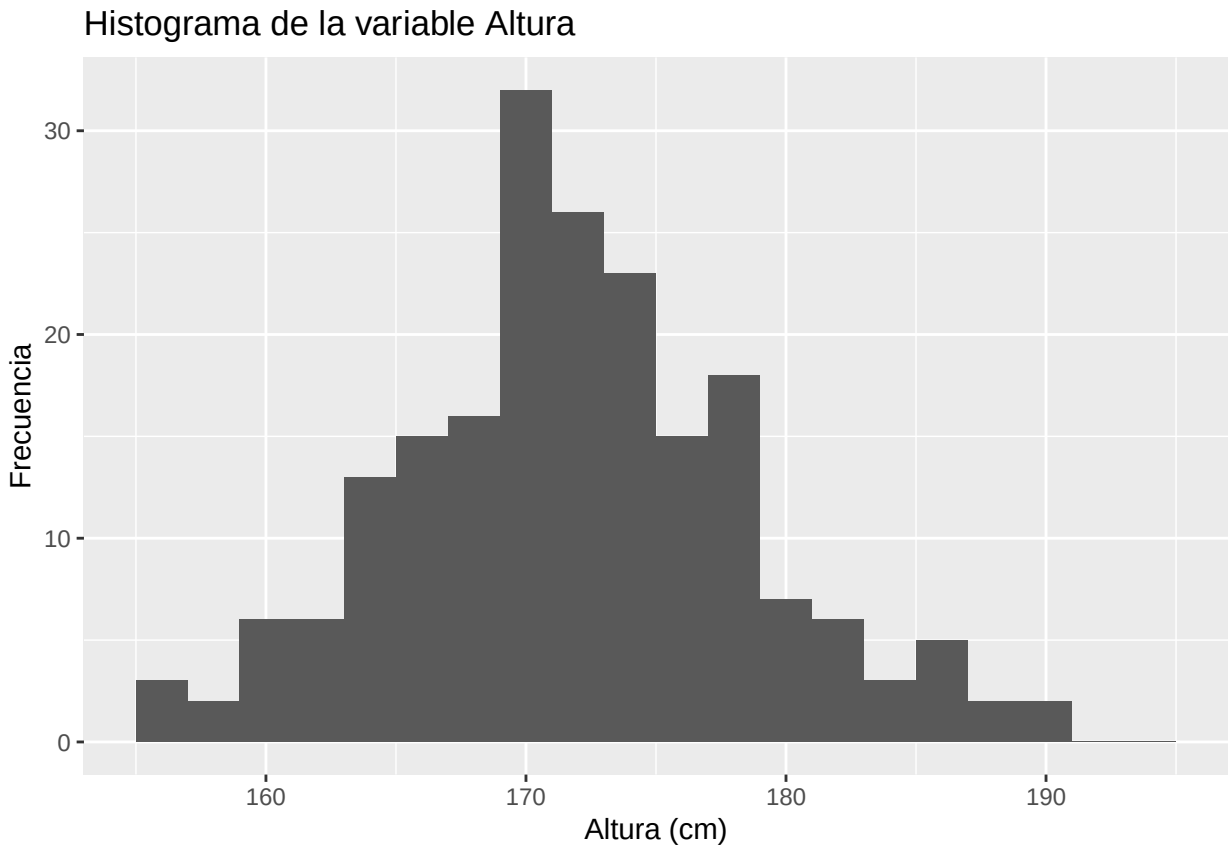
```
p8.2 + geom_histogram() +
  labs(
    title='Histograma de la variable Altura',
    x='Altura (cm)',
    y='Frecuencia'
  )
```

```
## `stat_bin()` using `bins = 30`. Pick better value `binwidth`.
```



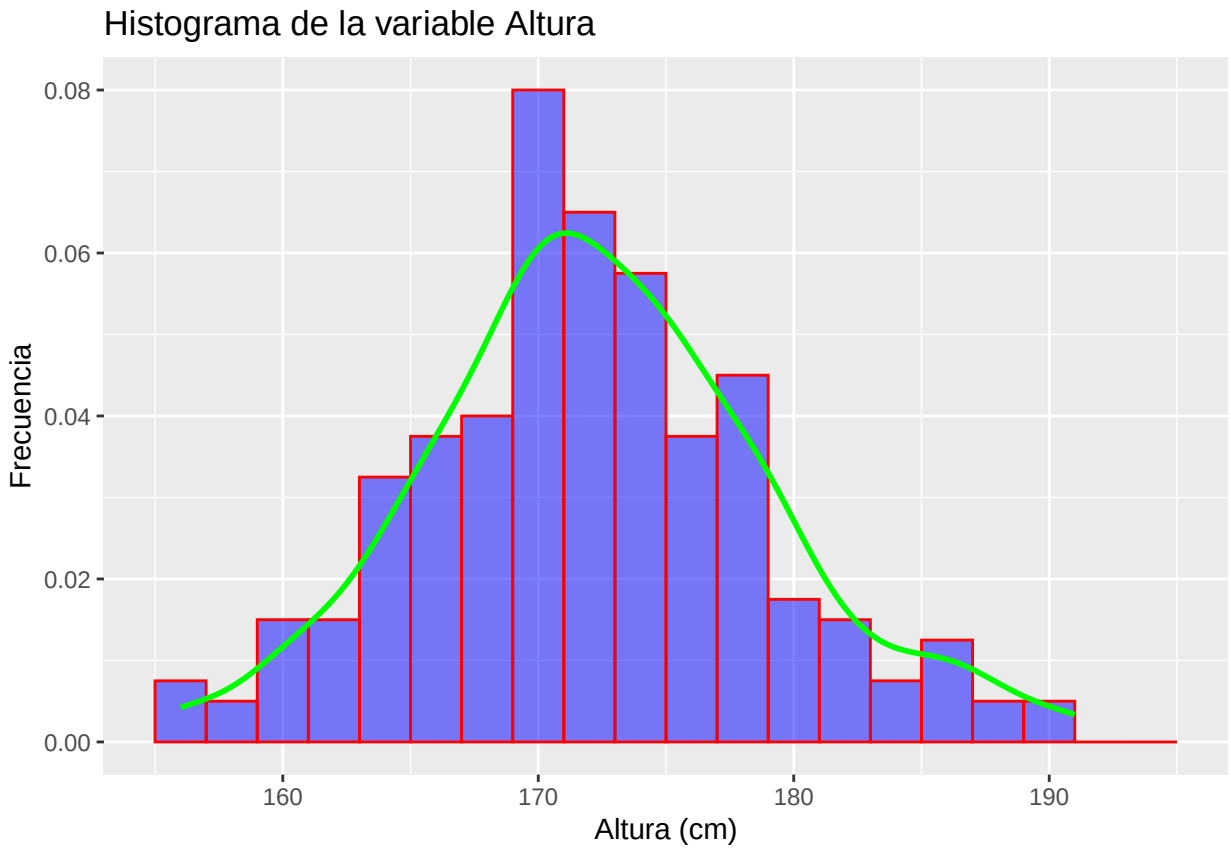
4. Ajusta el rango de representación entre 155 y 195, además fuerza que el histograma tenga 20 bins.(usa parámetro breaks)

```
p8.2 + geom_histogram(breaks=seq(155, 195, by=2)) +
  labs(
    title='Histograma de la variable Altura',
    x='Altura (cm)',
    y='Frecuencia'
  )
```



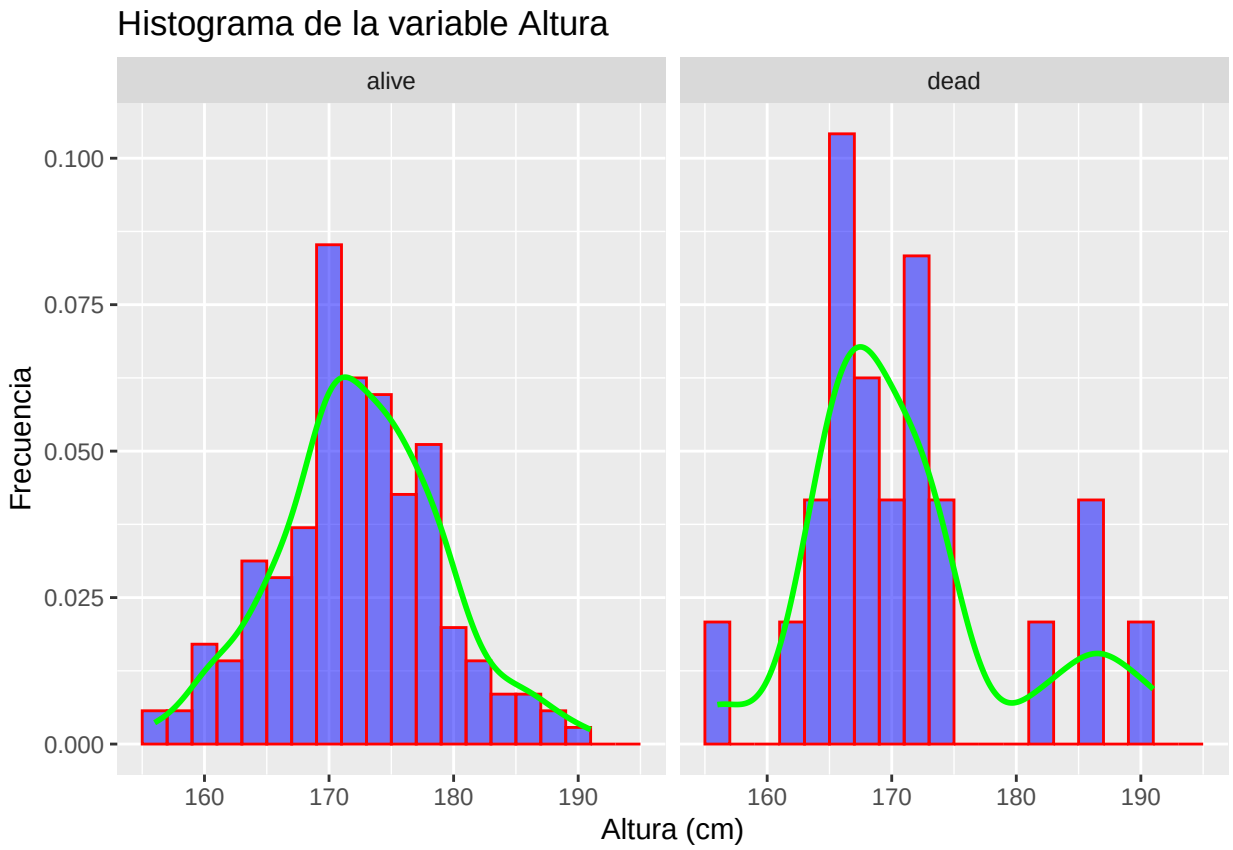
5. Haz que las barras del histograma sean de color azul con una grado de transparencia del 50 % y el contorno de color rojo. Añade la curva de distribución estimada de color verde.

```
p8.2 + geom_histogram(aes(y=after_stat(density)), breaks=seq(155, 195, by=2), fill='blue', alpha=0.5, c
  geom_density(
    color = "green",
    linewidth = 1
  ) +
  labs(
    title='Histograma de la variable Altura',
    x='Altura (cm)',
    y='Frecuencia'
  )
```



6. Representa el mismo histograma del apartado anterior para cada valor de la variable MORT, recuerda utilizar la función facet_grid().

```
p8.2 + geom_histogram(aes(y=after_stat(density)), breaks=seq(155, 195, by=2), fill='blue', alpha=0.5, c
  geom_density(
    color = "green",
    linewidth = 1
  ) +
  labs(
    title='Histograma de la variable Altura',
    x='Altura (cm)',
    y='Frecuencia'
  ) +
  facet_grid(.~MORT)
```




```
ggsave('./results/Ejercicio8.pdf', create.dir=T)
```

```
## Saving 6.5 x 4.5 in image
```